对于运动方程、观测方程：

位姿由变换矩阵描述，然后使用李代数进行优化，观测方程由相机成像模型给出，其中内参随机固定，而外参是相机的位姿。

但是受到噪声的影响，两个方程只能近似成立，因此需要在有噪声的数据中进行准确的状态（位姿、地图）估计。

一．状态估计问题

对于运动方程、观测方程，假设假设两个噪声均服从高斯分布：

$$\begin{cases} \boldsymbol{x}_k = f(\boldsymbol{x}_{k-1}, \boldsymbol{u}_k) + \boldsymbol{\omega}_k \\ \boldsymbol{z}_{k,j} = h(\boldsymbol{y}_j, \boldsymbol{x}_k) + \boldsymbol{v}_{k,j} \end{cases} \quad k = 1, \dots, N; j = 1, \dots, M$$

$$\boldsymbol{\omega}_k \sim N(0, \boldsymbol{R}_k), \boldsymbol{v}_k \sim N(0, \boldsymbol{Q}_{k,j})$$

- **状态估计问题：**

利用带噪声的数据$\boldsymbol{z}$和$\boldsymbol{u}$推断位姿$\boldsymbol{x}$和地图$\boldsymbol{y}$（以及它们的概率分布）。利用概率表示为求条件概率分布（将待估计状态记作一个状态变量）：

$$\begin{cases} P(\boldsymbol{x}|\boldsymbol{z}, \boldsymbol{u}) \\ \boldsymbol{x} = \{\boldsymbol{x}_1, \dots, \boldsymbol{x}_N, \boldsymbol{y}_1, \dots, \boldsymbol{y}_M\} \end{cases}$$

如果没有测量运动的传感器，只有图像，则条件概率分布简化为$P(\boldsymbol{x}|\boldsymbol{z})$，根据贝叶斯法则，有：

$$P(\boldsymbol{x}|\boldsymbol{z}) = \frac{P(\boldsymbol{z}|\boldsymbol{x})P(\boldsymbol{x})}{P(\boldsymbol{z})} \propto P(\boldsymbol{z}|\boldsymbol{x})P(\boldsymbol{x})$$

后验概率：$P(\boldsymbol{x}|\boldsymbol{z})$

似然：$P(\boldsymbol{z}|\boldsymbol{x})$

先验：$P(\boldsymbol{x})$

1.1 最大后验

直接求后验概率分布较为困难。

方法：求一个最优估计，使得在该状态下，**后验概率最大化**（Maximize a Posterior，MAP）：

$$\boldsymbol{x}^*_{\text{MAP}} = \text{argmax}\big(P(\boldsymbol{x}|\boldsymbol{z})\big) = \text{argmax}\big(P(\boldsymbol{z}|\boldsymbol{x})P(\boldsymbol{x})\big)$$

1.2 最大似然

如果不知道机器人大概在什么位置，即没有先验，则问题为求**最大似然估计**（Maximize Likelihood Estimation，MLE）：

$$\boldsymbol{x}^*_{\text{MLE}} = \text{argmax}\big(P(\boldsymbol{z}|\boldsymbol{x})\big)$$

似然：在现在位姿下，可能产生怎样的观测数据。

最大似然：在什么样的状态下，最可能产生现在的观测数据（观测数据已知）。

二．状态估计的概率解释

后端优化中，通常考虑一段时间内（或所有时间内）的状态估计问题，而且不仅使用过去的信息更新自己的状态，也会用未来的信息来更新自己

2.1 实际中的运动/观测方程

- **观测方程多于运动方程：**

实际中，机器人在一个位置通常只能看到一小部分路标。而且，由于视觉或激光 SLAM 特征点数量都多，所以实际当中观测方程数量会远远大于运动方程的数量。

- **如果没有运动方程：**

如果没有测量运动的装置，就没有明确的运动方程。此时可认为没有运动方程，或假设机器人不动，或机器人匀速运动。

此时，后端优化问题由多个观测方程组成。类似于 SfM（Structure from Motion）问题，即通过一组图像来恢复运动和结构。与 SfM 中不同的是，SLAM 中的图像有时间上的先后顺序，而 SfM 中允许使用完全无关的图像。

2.2 概率解释

令$\boldsymbol{x}_k$代表 k 时刻所有未知量，包含当前时刻的位姿、m 个路标点。且$\boldsymbol{z}_k$表示 k 时刻所有的观测。

$$\boldsymbol{x}_k \triangleq \{\boldsymbol{x}_k, \boldsymbol{y}_1, \dots, \boldsymbol{y}_m\}$$

两个方程改写为如下：

$$\begin{cases} \boldsymbol{x}_k = f(\boldsymbol{x}_{k-1}, \boldsymbol{u}_k) + \boldsymbol{\omega}_k \\ \boldsymbol{z}_k = h(\boldsymbol{x}_k) + \boldsymbol{v}_k \end{cases} \quad k = 1, \dots, N$$

利用过去 0-k 中的数据来估计当期时刻的状态分布：

$$P(\boldsymbol{x}_k | \boldsymbol{x}_0, \boldsymbol{u}_{1:k}, \boldsymbol{z}_{1:k})$$

根据贝叶斯法则，有：

$$P(\boldsymbol{x}_k | \boldsymbol{x}_0, \boldsymbol{u}_{1:k}, \boldsymbol{z}_{1:k}) \propto P(\boldsymbol{z}_k | \boldsymbol{x}_k) P(\boldsymbol{x}_k | \boldsymbol{x}_0, \boldsymbol{u}_{1:k}, \boldsymbol{z}_{1:k-1})$$

右式第一项为似然，由观测方程给定。第二项为先验，当前状态由过去所有状态估计得到，可将先验依次向前一时刻展开。

2.3 两类方法

- **滤波方法（EKF 等）：**

马尔可夫性：k 时刻状态只与 k–1 时刻状态有关。将先验按照 k-1 时刻展开如下：

$$P(\boldsymbol{x}_k | \boldsymbol{x}_0, \boldsymbol{u}_{1:k}, \boldsymbol{z}_{1:k-1}) = \int P(\boldsymbol{x}_k | \boldsymbol{x}_{k-1}, \boldsymbol{x}_0, \boldsymbol{u}_{1:k}, \boldsymbol{z}_{1:k-1}) P(\boldsymbol{x}_{k-1} | \boldsymbol{x}_0, \boldsymbol{u}_{1:k}, \boldsymbol{z}_{1:k-1}) \, \mathrm{d}\boldsymbol{x}_{k-1}$$

- **非线性优化方法：**
  k 时刻状态与之前所有状态有关。可将先验继续往前展开。