一. 最小二乘的引出

对于高维高斯分布，有如下推导：

高斯分布在负对数下有较好的数学形式。考虑一个任意的高维高斯分布 $\boldsymbol{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$，它的概率密度函数展开形式为:

$$P(\boldsymbol{x}) = \frac{1}{\sqrt{(2\pi)^N \det(\boldsymbol{\Sigma})}} \exp\left(-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right). \tag{6.8}$$

取它的负对数，则变为：

$$-\ln(P(\boldsymbol{x})) = \frac{1}{2}\ln\left((2\pi)^N \det(\boldsymbol{\Sigma})\right) + \frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu}). \tag{6.9}$$

对原分布求最大化相当于对负对数求最小化。在最小化上式的 $\boldsymbol{x}$ 时，第一项与 $\boldsymbol{x}$ 无关，可以略去。于是，只要最小化右侧的二次型项，就得到了对状态的最大似然估计。

状态估计问题中，假设运动、观测噪声服从高斯分布，根据运动、观测方程，二者数据也服从高斯分布，且条件概率分别为：

$$P(\boldsymbol{x}_k|\boldsymbol{x}_{k-1}, \boldsymbol{u}_k) = N(f(\boldsymbol{x}_{k-1}, \boldsymbol{u}_k), \boldsymbol{R}_k)$$
$$P(\boldsymbol{z}_{j,k}|\boldsymbol{x}_k, \boldsymbol{y}_j) = N(h(\boldsymbol{x}_k, \boldsymbol{y}_j), \boldsymbol{Q}_{k,j})$$

- **最小二乘问题：**

综合考虑二者，定义数据与估计的误差，且有误差的平方和。使该平方和最小的最优解，即为状态的最大似然估计。

$$\begin{cases} J(\boldsymbol{x}) = \sum_k {e_{v,k}}^T {\boldsymbol{R}_k}^{-1} e_{v,k} + \sum_k \sum_j {e_{y,k,j}}^T {\boldsymbol{Q}_{k,j}}^{-1} e_{y,k,j} \\ e_{v,k} = \boldsymbol{x}_k - f(\boldsymbol{x}_{k-1}, \boldsymbol{u}_k) \\ e_{y,k,j} = \boldsymbol{z}_{j,k} - h(\boldsymbol{x}_k, \boldsymbol{y}_j) \end{cases}$$

二. 非线性最小二乘

对于最小二乘问题：

$$\min_x \frac{1}{2}\|f(\boldsymbol{x})\|_2^2$$

迭代方法求解：从一个初始值出发，不断寻找梯度并下降，直到增量非常小，无法再使函数下降，此时算法收敛，目标达到了一个极小。对于增量的确定，分为多种方法。

1. 给定某个初始值 $\boldsymbol{x}_0$。
2. 对于第 k 次迭代，寻找一个增量 $\Delta \boldsymbol{x}_k$，使得 $\|f(\boldsymbol{x}_k + \Delta \boldsymbol{x}_k)\|_2^2$ 达到极小值。
3. 若 $\Delta \boldsymbol{x}_k$ 足够小，则停止。
4. 否则，令 $\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \Delta \boldsymbol{x}_k$，返回 2.

2.1 一阶和二阶梯度法（牛顿法）

求解增量最直观的方法。但算法中矩阵$\boldsymbol{H}$的计算困难，因此不常用

将目标函数在$\boldsymbol{x}$附近进行泰勒展开。其中$\boldsymbol{J}(\boldsymbol{x})$是$\|f(\boldsymbol{x})\|_2{}^2$关于$\boldsymbol{x}$的导数（雅可比矩阵），而$\boldsymbol{H}$是二阶导数（海塞矩阵）。

$$\|f(\boldsymbol{x}+\Delta\boldsymbol{x})\|_2{}^2 = \|f(\boldsymbol{x})\|_2{}^2 + \boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x} + \frac{1}{2}\Delta\boldsymbol{x}^T\boldsymbol{H}\Delta\boldsymbol{x} + \cdots$$

- **一阶：**

取前两项，令其值等于0，可得到增量的解如下。即沿着反向梯度方向前进即可。实际中可加上步长系数，即最快的下降速度。

$$\Delta\boldsymbol{x}^* = -\boldsymbol{J}^T(\boldsymbol{x})$$

- **二阶：**

取前三项，关于求导并令为0，得到增量的解如下。

$$\boldsymbol{H}\Delta\boldsymbol{x} = -\boldsymbol{J}^T(\boldsymbol{x})$$

2.2 高斯牛顿法

2.2.1 推导

Gauss Newton 是最优化算法里面最简单的方法之一。它的思想是将 $f(\boldsymbol{x})$ 进行一阶的泰勒展开（请注意不是目标函数 $f(\boldsymbol{x})^2$）：

$$f(\boldsymbol{x}+\Delta\boldsymbol{x}) \approx f(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}. \tag{6.19}$$

这里 $\boldsymbol{J}(\boldsymbol{x})$ 为 $f(\boldsymbol{x})$ 关于 $\boldsymbol{x}$ 的导数，实际上是一个 $m \times n$ 的矩阵，也是一个雅可比矩阵。根据前面的框架，当前的目标是为了寻找下降矢量 $\Delta\boldsymbol{x}$，使得 $\|f(\boldsymbol{x}+\Delta\boldsymbol{x})\|^2$ 达到最小。为了求 $\Delta\boldsymbol{x}$，我们需要解一个线性的最小二乘问题：

$$\Delta\boldsymbol{x}^* = \arg\min_{\Delta\boldsymbol{x}} \frac{1}{2}\|f(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}\|^2. \tag{6.20}$$

这个方程与之前有什么不一样呢？根据极值条件，将上述目标函数对 $\Delta\boldsymbol{x}$ 求导，并令导数为零。由于这里考虑的是 $\Delta\boldsymbol{x}$ 的导数（而不是 $\boldsymbol{x}$），我们最后将得到一个线性的方程。为此，先展开目标函数的平方项：

$$\begin{aligned}\frac{1}{2}\|f(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}\|^2 &= \frac{1}{2}(f(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x})^T (f(\boldsymbol{x}) + \boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}) \\ &= \frac{1}{2}\left(\|f(\boldsymbol{x})\|_2^2 + 2f(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x} + \Delta\boldsymbol{x}^T\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}\right).\end{aligned}$$

求上式关于 $\Delta\boldsymbol{x}$ 的导数，并令其为零：

$$2\boldsymbol{J}(\boldsymbol{x})^T f(\boldsymbol{x}) + 2\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x} = \boldsymbol{0}.$$

可以得到如下方程组：

$$\boldsymbol{J}(\boldsymbol{x})^T\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x} = -\boldsymbol{J}(\boldsymbol{x})^T f(\boldsymbol{x}). \tag{6.21}$$

注意，我们要求解的变量是 $\Delta\boldsymbol{x}$，因此这是一个**线性方程组**，我们称它为**增量方程**，也可以称为**高斯牛顿方程** (Gauss Newton equations) 或者**正规方程** (Normal equations)。我们把左边的系数定义为 $\boldsymbol{H}$，右边定义为 $\boldsymbol{g}$，那么上式变为：

$$\boldsymbol{H}\Delta\boldsymbol{x} = \boldsymbol{g}. \tag{6.22}$$

这里把左侧记作 $\boldsymbol{H}$ 是有意义的。对比牛顿法可见，Gauss-Newton 用 $\boldsymbol{J}^T\boldsymbol{J}$ 作为牛顿法中二阶 Hessian 矩阵的近似，从而省略了计算 $\boldsymbol{H}$ 的过程。

2.2.2 总结

1. 给定初始值 $\boldsymbol{x}_0$。
2. 对于第 k 次迭代，求出当前的雅可比矩阵 $\boldsymbol{J}(\boldsymbol{x}_k)$ 和误差 $f(\boldsymbol{x}_k)$。
3. 求解增量方程：$\boldsymbol{H}\Delta\boldsymbol{x}_k = \boldsymbol{g}$.
4. 若 $\Delta\boldsymbol{x}_k$ 足够小，则停止。否则，令 $\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \Delta\boldsymbol{x}_k$，返回 2.

2.2.3 优缺点

从算法步骤中可以看到，增量方程的求解占据着主要地位。原则上，它要求我们所用的近似 $\boldsymbol{H}$ 矩阵是可逆的（而且是正定的），但实际数据中计算得到的 $\boldsymbol{J}^T\boldsymbol{J}$ 却只有半正定性。也就是说，在使用 Gauss Newton 方法时，可能出现 $\boldsymbol{J}^T\boldsymbol{J}$ 为奇异矩阵或者病态 (ill-condition) 的情况，此时增量的稳定性较差，导致算法不收敛。更严重的是，就算我们假设 $\boldsymbol{H}$ 非奇异也非病态，如果我们求出来的步长 $\Delta\boldsymbol{x}$ 太大，也会导致我们采用的局部近似 (6.19) 不够准确，这样一来我们甚至都无法保证它的迭代收敛，哪怕是让目标函数变得更大都是有可能的。

尽管 Gauss Newton 法有这些缺点，但是它依然值得我们去学习，因为在非线性优化里，相当多的算法都可以归结为 Gauss Newton 法的变种。这些算法都借助了 Gauss Newton 法的思想并且通过自己的改进修正 Gauss Newton 法的缺点。例如一些**线搜索方法** (line search method)，这类改进就是加入了一个标量 α，在确定了 $\Delta\boldsymbol{x}$ 进一步找到 α 使得 $\|f(\boldsymbol{x}+\alpha\Delta\boldsymbol{x})\|^2$ 达到最小，而不是像 Gauss Newton 法那样简单地令 $\alpha=1$。

2.3 列文伯格-马垮尔特法

2.3.1 改进点

由于 Gauss-Newton 方法中采用的近似二阶泰勒展开只能在展开点附近有较好的近似效果，所以我们很自然地想到应该给 $\Delta\boldsymbol{x}$ 添加一个信赖区域（Trust Region），不能让它太大而使得近似不准确。非线性优化种有一系列这类方法，这类方法也被称之为**信赖区域方法** (Trust Region Method)。在信赖区域里边，我们认为近似是有效的；出了这个区域，近似可能会出问题。

那么如何确定这个信赖区域的范围呢？一个比较好的方法是根据我们的近似模型跟实际函数之间的差异来确定这个范围：如果差异小，我们就让范围尽可能大；如果差异大，我们就缩小这个近似范围。因此，考虑使用

$$\rho=\frac{f(\boldsymbol{x}+\Delta\boldsymbol{x})-f(\boldsymbol{x})}{\boldsymbol{J}(\boldsymbol{x})\Delta\boldsymbol{x}}. \tag{6.23}$$

来判断泰勒近似是否够好。ρ 的分子是实际函数下降的值，分母是近似模型下降的值。如果 ρ 接近于 1，则近似是好的。如果 ρ 太小，说明实际减小的值远少于近似减小的值，则认为近似比较差，需要缩小近似范围。反之，如果 ρ 比较大，则说明实际下降的比预计的更大，我们可以放大近似范围。

2.3.2 推导

1. 给定初始值 $\boldsymbol{x}_0$，以及初始优化半径 μ。

2. 对于第 k 次迭代，求解：

$$\min_{\Delta \boldsymbol{x}_k} \frac{1}{2} \| f(\boldsymbol{x}_k) + \boldsymbol{J}(\boldsymbol{x}_k) \Delta \boldsymbol{x}_k \|^2, \quad s.t. \| \boldsymbol{D} \Delta \boldsymbol{x}_k \|^2 \leq \mu,$$

   这里 μ 是信赖区域的半径，$\boldsymbol{D}$ 将在后文说明。

3. 计算 ρ。

4. 若 $\rho > \frac{3}{4}$，则 $\mu = 2\mu$；

5. 若 $\rho < \frac{1}{4}$，则 $\mu = 0.5\mu$；

6. 如果 ρ 大于某阈值，认为近似可行。令 $\boldsymbol{x}_{k+1} = \boldsymbol{x}_k + \Delta \boldsymbol{x}_k$。

7. 判断算法是否收敛。如不收敛则返回 2，否则结束。

这里近似范围扩大的倍数和阈值都是经验值，可以替换成别的数值。在式（6.24）中，我们把增量限定于一个半径为 μ 的球中，认为只在这个球内才是有效的。带上 $\boldsymbol{D}$ 之后，这个球可以看成一个椭球。在 Levenberg 提出的优化方法中，把 $\boldsymbol{D}$ 取成单位阵 $\boldsymbol{I}$，相当于直接把 $\Delta \boldsymbol{x}$ 约束在一个球中。随后，Marqaurdt 提出将 $\boldsymbol{D}$ 取成非负数对角阵——实际中通常用 $\boldsymbol{J}^T \boldsymbol{J}$ 的对角元素平方根，使得在梯度小的维度上约束范围更大一些。

不论如何，在 L-M 优化中，我们都需要解式（6.24）那样一个子问题来获得梯度。这个子问题是带不等式约束的优化问题，我们用 Lagrange 乘子将它转化为一个无约束优化问题：

$$\min_{\Delta \boldsymbol{x}_k} \frac{1}{2} \| f(\boldsymbol{x}_k) + \boldsymbol{J}(\boldsymbol{x}_k) \Delta \boldsymbol{x}_k \|^2 + \frac{\lambda}{2} \| \boldsymbol{D} \Delta \boldsymbol{x} \|^2. \tag{6.25}$$

这里 λ 为 Lagrange 乘子。类似于 Gauss-Newton 中的做法，把它展开后，我们发现该问题的核心仍是计算增量的线性方程：

$$\left(\boldsymbol{H} + \lambda \boldsymbol{D}^T \boldsymbol{D} \right) \Delta \boldsymbol{x} = \boldsymbol{g}. \tag{6.26}$$

可以看到，增量方程相比于 Gauss-Newton，多了一项 $\lambda \boldsymbol{D}^T \boldsymbol{D}$。如果考虑它的简化形式，即 $\boldsymbol{D} = \boldsymbol{I}$，那么相当于求解：

$$(\boldsymbol{H} + \lambda \boldsymbol{I}) \Delta \boldsymbol{x} = \boldsymbol{g}.$$

2.3.3 优缺点

我们看到，当参数 λ 比较小时，$\boldsymbol{H}$ 占主要地位，这说明二次近似模型在该范围内是比较好的，L-M 方法更接近于 G-N 法。另一方面，当 λ 比较大时，$\lambda \boldsymbol{I}$ 占据主要地位，L-M 更接近于一阶梯度下降法（即最速下降），这说明附近的二次近似不够好。L-M 的求解方式，可在一定程度上避免线性方程组的系数矩阵的非奇异和病态问题，提供更稳定更准确的增量 $\Delta \boldsymbol{x}$。