一. 直接法的引出

特征点法缺点：

（1）**耗时。**关键点的提取与描述子的计算非常耗时。

（2）**图像信息丢失。**使用特征点时，忽略了除特征点以外的所有信息。只使用特征点丢弃了大部分可能有用的图像信息。

（3）**特征缺失。**相机有时会运动到特征缺失的地方，这些地方没有明显的纹理信息，可能找不到足够的匹配点来计算相机运动。

光流法：使用光流跟踪替换描述子匹配，估计相机运动仍使用对极几何、PnP、ICP 算法。

- 保留特征点，但只计算关键点，不计算描述子。同时，使用**光流法**（Optical Flow）来跟踪特征点的运动。这样可以回避计算和匹配描述子带来的时间，但光流本身的计算需要一定时间；

直接法：根据图像的像素灰度信息（最小化广度误差）计算相机运动。

- 只计算关键点，不计算描述子。同时，使用**直接法**（Direct Method）来计算特征点在下一时刻图像的位置。这同样可以跳过描述子的计算过程，而且直接法的计算更加简单。
- 既不计算关键点、也不计算描述子，而是根据像素灰度的差异，**直接**计算相机运动。

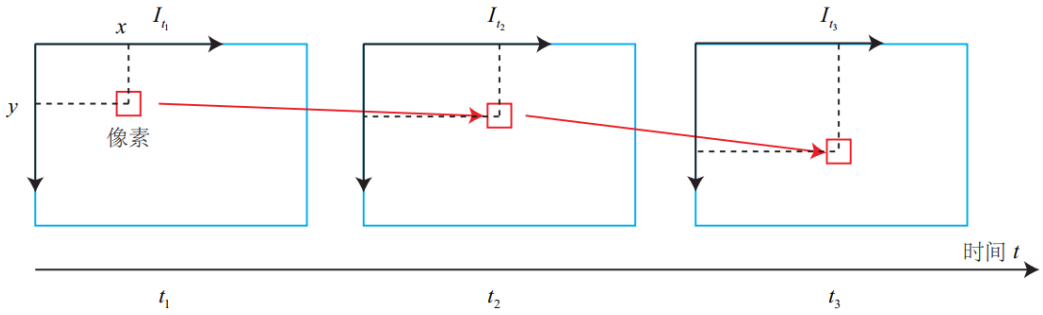
直接法分类：

稀疏、稠密、半稠密。（特征点法只能重构稀疏特征点，构建稀疏地图）

二. 光流法

2.1 光流

光流：一种描述像素随着时间，在图像之间运动的方法。计算部分像素运动的为稀疏光流，计算所有像素的为稠密光流。



2.2 LK 光流法推导

- **灰度不变假设：**

同一个空间点的像素灰度值，在各个图像中是固定不变的。如t时刻位于(x,y)处的像素，$t+dt$时刻运动到$(x+dx,y+dy)$处，灰度不变：

$$\boldsymbol{I}(x+dx,y+dy,t+dt)=\boldsymbol{I}(x,y,t)$$

该假设是一个很强的假设，实际当中很可能不成立。

- **推导：**

（1）进行一阶泰勒展开：

$$\boldsymbol{I}(x+dx,y+dy,t+dt)\approx\boldsymbol{I}(x,y,t)+\frac{\partial\boldsymbol{I}}{\partial x}dx+\frac{\partial\boldsymbol{I}}{\partial y}dy+\frac{\partial\boldsymbol{I}}{\partial t}dt$$

根据灰度不变假设，有：

$$\frac{\partial\boldsymbol{I}}{\partial x}dx+\frac{\partial\boldsymbol{I}}{\partial y}dy+\frac{\partial\boldsymbol{I}}{\partial t}dt=0$$

两边同除以dt：

$$\frac{\partial\boldsymbol{I}}{\partial x}\frac{dx}{dt}+\frac{\partial\boldsymbol{I}}{\partial y}\frac{dy}{dt}=-\frac{\partial\boldsymbol{I}}{\partial t}$$

记$u=dx/dt$、$v=dx/dt$分别为像素在两轴方向的速度；$\boldsymbol{I}_x=\partial\boldsymbol{I}/\partial x$、$\boldsymbol{I}_y=\partial\boldsymbol{I}/\partial y$分别为图像在该点处两轴方向上的梯度。$\boldsymbol{I}_t$为图像灰度对时间的变化量。

$$[\boldsymbol{I}_x\quad\boldsymbol{I}_y]\begin{bmatrix}u\\v\end{bmatrix}=-\boldsymbol{I}_t$$

（2）光流法的目标是跟踪特征点的运动，因此目标是求解u和v。考虑一个大小为ω^2的窗口，含有ω^2数量的像素。该窗口内像素具有同样的运动：

$$\boldsymbol{A}\begin{bmatrix}u\\v\end{bmatrix}=-\boldsymbol{b}$$

$$\boldsymbol{A}=\begin{bmatrix}[\boldsymbol{I}_x\quad\boldsymbol{I}_y]_1\\\vdots\\[\boldsymbol{I}_x\quad\boldsymbol{I}_y]_k\end{bmatrix},\qquad b=\begin{bmatrix}\boldsymbol{I}_{tk}\\\vdots\\\boldsymbol{I}_{tk}\end{bmatrix},\qquad k=\omega^2$$

（3）利用最小二乘法，求解该超定线性方程。关于最小二乘法：http://www.dengke.xyz/archives/2573。

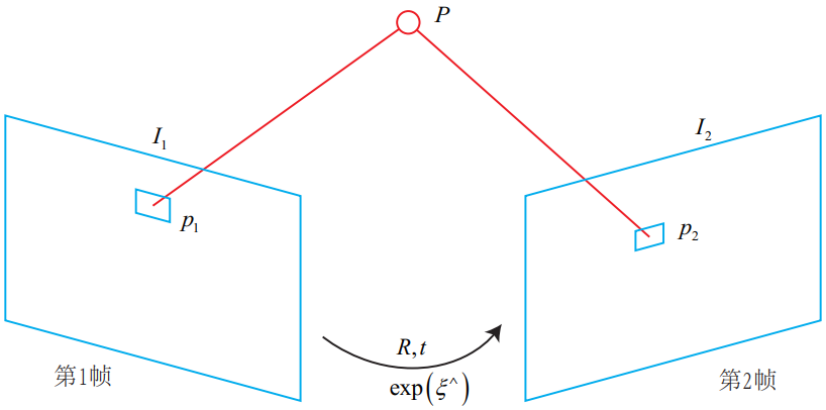
$$\begin{bmatrix}u\\v\end{bmatrix}^*=-(\boldsymbol{A}^T\boldsymbol{A})^{-1}\boldsymbol{A}^T\boldsymbol{b}$$

三．直接法

3.1 推导

- **目的：**

  求第一帧到第二帧的相对位姿变换。



- **优化目标及求导：**

  优化相机的位姿，来寻找与$\boldsymbol{p}_1$更相似的$\boldsymbol{p}_2$。（因为没有特征匹配，无法得知哪一个$\boldsymbol{p}_1$和$\boldsymbol{p}_2$对应同一个空间点）

  （1）定义光度误差：

$$e = \boldsymbol{I}_1(\boldsymbol{p}_1) - \boldsymbol{I}_2(\boldsymbol{p}_2)$$

$$\begin{cases} \boldsymbol{p}_1 = \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}_1 = \frac{1}{Z_1}\boldsymbol{K}\boldsymbol{P} \\ \boldsymbol{p}_2 = \begin{bmatrix} u \\ v \\ 1 \end{bmatrix}_2 = \frac{1}{Z_2}\boldsymbol{K}(\boldsymbol{R}\boldsymbol{P} + \boldsymbol{t}) = \frac{1}{Z_2}\boldsymbol{K}(\exp(\boldsymbol{\xi}^\wedge)\boldsymbol{P})_{1:3} \end{cases}$$

  （2）定义优化目标：优化相机位姿$\boldsymbol{\xi}$，使得光度误差最小（依赖灰度不变假设）。

$$\min_{\boldsymbol{\xi}} J(\boldsymbol{\xi}) = \min_{\boldsymbol{\xi}} \|e\|^2 = \min_{\boldsymbol{\xi}} \sum_{i=1}^{N} e_i^T e_i$$

  （3）求导数关系：根据《SLAM 优化 1：非线性优化》求解上述最小二乘问题，需要用到导数。使用李代数的扰动模型求导，给$\exp(\boldsymbol{\xi})$左乘扰动$\exp(\delta\boldsymbol{\xi})$：

$$
\begin{aligned}
e(\boldsymbol{\xi} \oplus \delta\boldsymbol{\xi}) &= \boldsymbol{I}_1 \left(\frac{1}{Z_1}\boldsymbol{K}\boldsymbol{P}\right) - \boldsymbol{I}_2 \left(\frac{1}{Z_2}\boldsymbol{K}\exp(\delta\boldsymbol{\xi}^\wedge)\exp(\boldsymbol{\xi}^\wedge)\boldsymbol{P}\right) \\
&\approx \boldsymbol{I}_1 \left(\frac{1}{Z_1}\boldsymbol{K}\boldsymbol{P}\right) - \boldsymbol{I}_2 \left(\frac{1}{Z_2}\boldsymbol{K}(1+\delta\boldsymbol{\xi}^\wedge)\exp(\boldsymbol{\xi}^\wedge)\boldsymbol{P}\right) \\
&= \boldsymbol{I}_1 \left(\frac{1}{Z_1}\boldsymbol{K}\boldsymbol{P}\right) - \boldsymbol{I}_2 \left(\frac{1}{Z_2}\boldsymbol{K}\exp(\boldsymbol{\xi}^\wedge)\boldsymbol{P} + \frac{1}{Z_2}\boldsymbol{K}\delta\boldsymbol{\xi}^\wedge\exp(\boldsymbol{\xi}^\wedge)\boldsymbol{P}\right).
\end{aligned}
$$

类似于上一章，记

$$
\begin{aligned}
\boldsymbol{q} &= \delta\boldsymbol{\xi}^\wedge \exp(\boldsymbol{\xi}^\wedge)\boldsymbol{P}, \\
\boldsymbol{u} &= \frac{1}{Z_2}\boldsymbol{K}\boldsymbol{q}.
\end{aligned}
$$

这里的 $\boldsymbol{q}$ 为 $\boldsymbol{P}$ 在扰动之后，位于第二个相机坐标系下的坐标，而 $\boldsymbol{u}$ 为它的像素坐标。

一阶泰勒展开：

$$
\begin{aligned}
e(\boldsymbol{\xi} \oplus \delta\boldsymbol{\xi}) &= \boldsymbol{I}_1 \left(\frac{1}{Z_1}\boldsymbol{K}\boldsymbol{P}\right) - \boldsymbol{I}_2 \left(\frac{1}{Z_2}\boldsymbol{K}\exp(\boldsymbol{\xi}^\wedge)\boldsymbol{P} + \boldsymbol{u}\right) \\
&\approx \boldsymbol{I}_1 \left(\frac{1}{Z_1}\boldsymbol{K}\boldsymbol{P}\right) - \boldsymbol{I}_2 \left(\frac{1}{Z_2}\boldsymbol{K}\exp(\boldsymbol{\xi}^\wedge)\boldsymbol{P}\right) - \frac{\partial \boldsymbol{I}_2}{\partial \boldsymbol{u}}\frac{\partial \boldsymbol{u}}{\partial \boldsymbol{q}}\frac{\partial \boldsymbol{q}}{\partial \delta\boldsymbol{\xi}}\delta\boldsymbol{\xi} \\
&= e(\boldsymbol{\xi}) - \frac{\partial \boldsymbol{I}_2}{\partial \boldsymbol{u}}\frac{\partial \boldsymbol{u}}{\partial \boldsymbol{q}}\frac{\partial \boldsymbol{q}}{\partial \delta\boldsymbol{\xi}}\delta\boldsymbol{\xi}.
\end{aligned}
$$

- **3 项：**

1. $\partial \boldsymbol{I}_2 / \partial \boldsymbol{u}$ 为 $\boldsymbol{u}$ 处的像素梯度；

①

2. $\partial \boldsymbol{u} / \partial \boldsymbol{q}$ 为投影方程关于相机坐标系下的三维点的导数。记 $\boldsymbol{q} = [X, Y, Z]^T$，根据上一节的推导，导数为：

②
$$
\frac{\partial \boldsymbol{u}}{\partial \boldsymbol{q}} = \begin{bmatrix} \frac{\partial u}{\partial X} & \frac{\partial u}{\partial Y} & \frac{\partial u}{\partial Z} \\ \frac{\partial v}{\partial X} & \frac{\partial v}{\partial Y} & \frac{\partial v}{\partial Z} \end{bmatrix} = \begin{bmatrix} \frac{f_x}{Z} & 0 & -\frac{f_x X}{Z^2} \\ 0 & \frac{f_y}{Z} & -\frac{f_y Y}{Z^2} \end{bmatrix}. \tag{8.13}
$$

3. $\partial \boldsymbol{q} / \partial \delta\boldsymbol{\xi}$ 为变换后的三维点对变换的导数，这在李代数章节已经介绍过了：

③
$$
\frac{\partial \boldsymbol{q}}{\partial \delta\boldsymbol{\xi}} = [\boldsymbol{I}, -\boldsymbol{q}^\wedge]. \tag{8.14}
$$

在实践中，由于后两项只与三维点 $\boldsymbol{q}$ 有关，而与图像无关，我们经常把它合并在一起：

$$
\frac{\partial \boldsymbol{u}}{\partial \delta\boldsymbol{\xi}} = \begin{bmatrix} \frac{f_x}{Z} & 0 & -\frac{f_x X}{Z^2} & -\frac{f_x XY}{Z^2} & f_x + \frac{f_x X^2}{Z^2} & -\frac{f_x Y}{Z} \\ 0 & \frac{f_y}{Z} & -\frac{f_y Y}{Z^2} & -f_y - \frac{f_y Y^2}{Z^2} & \frac{f_y XY}{Z^2} & \frac{f_y X}{Z} \end{bmatrix}. \tag{8.15}
$$

这个 2×6 的矩阵在上一讲中也出现过。于是，我们推导了误差相对于李代数的雅可比矩阵：

$$
\boldsymbol{J} = -\frac{\partial \boldsymbol{I}_2}{\partial \boldsymbol{u}}\frac{\partial \boldsymbol{u}}{\partial \delta\boldsymbol{\xi}}. \tag{8.16}
$$

3.2 总结

3.2.1 分类

1. P 来自于稀疏关键点，我们称之为稀疏直接法。通常我们使用数百个至上千个关键点，并且像 L-K 光流那样，假设它周围像素也是不变的。这种稀疏直接法不必计算描述子，并且只使用数百个像素，因此速度最快，但只能计算稀疏的重构。
2. P 来自部分像素。我们看到式（8.16）中，如果像素梯度为零，整一项雅可比就为零，不会对计算运动增量有任何贡献。因此，可以考虑只使用带有梯度的像素点，舍弃像素梯度不明显的地方。这称之为半稠密（Semi-Dense）的直接法，可以重构一个半稠密结构。
3. P 为所有像素，称为稠密直接法。稠密重构需要计算所有像素（一般几十万至几百万个），因此多数不能在现有的 CPU 上实时计算，需要 GPU 的加速。但是，如前面所讨论的，梯度不明显的点，在运动估计中不会有太大贡献，在重构时也会难以估计位置。

3.2.2 优缺点

- 可以省去计算特征点、描述子的时间。
- 只要求有像素梯度即可，无须特征点。因此，直接法可以在特征缺失的场合下使用。比较极端的例子是只有渐变的一张图像。它可能无法提取角点类特征，但可以用直接法估计它的运动。
- 可以构建半稠密乃至稠密的地图，这是特征点法无法做到的。

另一方面，它的缺点也很明显：

- **非凸性**——直接法完全依靠梯度搜索，降低目标函数来计算相机位姿。其目标函数中需要取像素点的灰度值，而图像是强烈非凸的函数。这使得优化算法容易进入极小，只在运动很小时直接法才能成功。
- **单个像素没有区分度**。找一个和他像的实在太多了！——于是我们要么计算图像块，要么计算复杂的相关性。由于每个像素对改变相机运动的“意见”不一致。只能少数服从多数，以数量代替质量。
- **灰度值不变是很强的假设**。如果相机是自动曝光的，当它调整曝光参数时，会使得图像整体变亮或变暗。光照变化时亦会出现这种情况。特征点法对光照具有一定的容忍性，而直接法由于计算灰度间的差异，整体灰度变化会破坏灰度不变假设，使算法失败。针对这一点，目前的直接法开始使用更细致的光度模型标定相机，以便在曝光时间变化时也能让直接法工作。