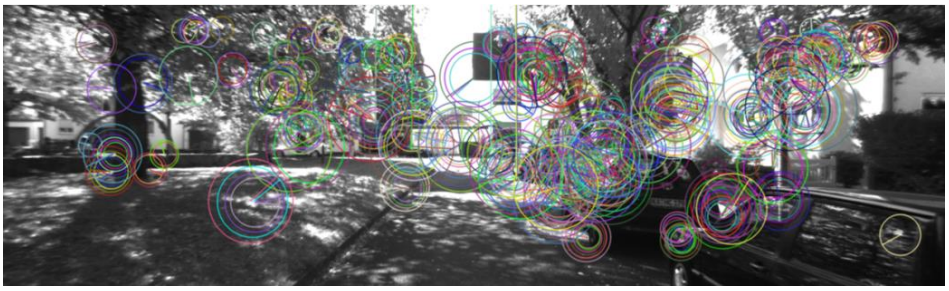
# 一. ORB 特征

ORB 特征 = Oriented_FAST 关键点 + BRIEF 描述子



## 1.1 关键点

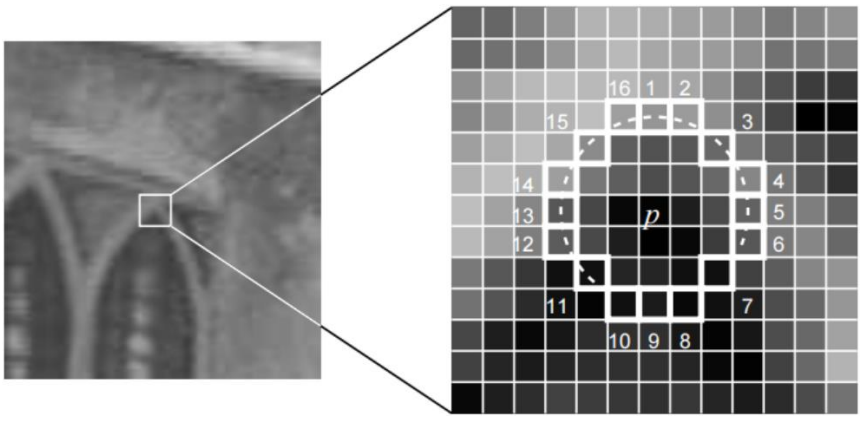
### 1.1.1 FAST 关键点

- **思想：**

FAST 是一种角点，主要检测像素灰度变化明显的地方。如果一个像素与它邻域的像素差别较大，那它更可能是角点。

- **检测算法：**

1. 在图像中选取像素 $p$，假设它的亮度为 $I_p$。
2. 设置一个阈值 $T$(比如 $I_p$ 的 20%)。
3. 以像素 $p$ 为中心, 选取半径为 3 的圆上的 16 个像素点。
4. 假如选取的圆上，有连续的 N 个点的亮度大于 $I_p + T$ 或小于 $I_p - T$，那么像素 $p$ 可以被认为是特征点 (N 通常取 12，即为 FAST-12。其它常用的 N 取值为 9 和 11，他们分别被称为 FAST-9，FAST-11)。
5. 循环以上四步，对每一个像素执行相同的操作。




- **FAST-12 算法的预检测：**

直接检测邻域圆上的第 1、5、9、13 个像素的亮度，只有当其中三个同时满足算法第 4 步的条件，当前像素才可能是一个角点，否则应该直接排除。

### 1.1.2 改进

- **提取固定数量的特征：**

指定最终要提取的角点数量 N，对原始 FAST 角点分别计算 Harris 响应值，然后选取前 N 个具有最大响应值的角点，作为最终的角点集合。

- **添加尺度和旋转：**

（1）尺度：构建图像金字塔，在金字塔的每一层上检测 FAST 角点来实现。

（2）旋转：

1. 在一个小的图像块 $B$ 中，定义图像块的矩为：

$$m_{pq} = \sum_{x,y \in B} x^p y^q I(x,y), \quad p,q = \{0,1\}.$$

2. 通过矩可以找到图像块的质心：

$$C = (\frac{m_{10}}{m_{00}}, \frac{m_{01}}{m_{00}}).$$

3. 连接图像块的几何中心 $O$ 与质心 $C$，得到一个方向向量 $\overrightarrow{OC}$，于是特征点的方向可以定义为：

$$\theta = \arctan(m_{01}/m_{10}).$$

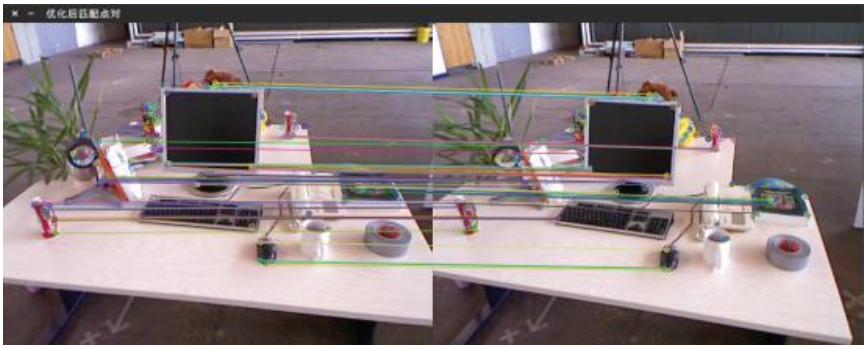
## 1.2 描述子

BRIEF 描述子：一种二进制描述子，其描述向量由数个 0 和 1 组成，这里的 0 和 1 编码了关键点附近两个像素（$p$、$q$）的大小关系：如果 $p$ 比 $q$ 大，则取 1；反之取 0。

选取 $p$、$q$ 点：按照某种概率分布，随机挑选其位置。常见选取 128 对点，BRIEF-128。

## 1.3 特征匹配

数据关联问题：确定当前看到的路标与之前看到的路标之间的对应关系。通过描述子的差异判断哪些特征点为同一个点。



暴力匹配：对左图某特征点的 BRIEF，测量与右图所有特征点 BRIEF 的汉明距离。排序后，取最近的一个作为匹配点（两个二进制串之间的汉明距离，是它们不同位数的个数）。

快速：快速最近邻（FLANN）。

# 二. 2D-2D：对极几何

**对极几何：**已知两幅图中若干对配对好的特征点，如何恢复出在两帧之间摄像机的运动。

**应用场景：**单目相机。

## 2.1 对极约束和本质矩阵

- **几何关系：**

  运动变化：$\boldsymbol{R}$和$\boldsymbol{t}$（第一帧到第二帧）

  成像平面：$I_1$、$I_2$

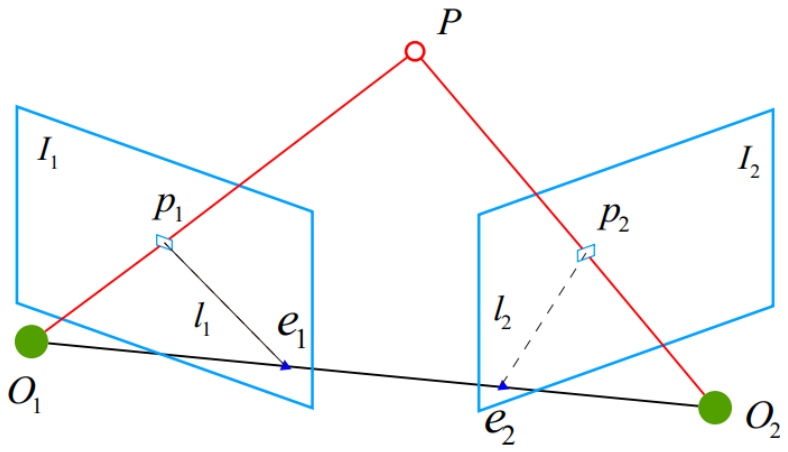
  投影：$p_1$、$p_2$

  极平面：$P$、$O_1$、$O_2$确定的平面

  基线：$O_1O_2$

  极点：基线和两成像平面的交点$e_1$、$e_2$

  极线：极平面和成像平面的交线$l_1$、$l_2$




- **推导：**

现在，我们从代数角度来看一下这里出现的几何关系。在第一帧的坐标系下，设 $P$ 的空间位置为：

$$\boldsymbol{P} = [X, Y, Z]^T.$$

根据第 5 讲介绍的针孔相机模型，我们知道两个像素点 $\boldsymbol{p}_1, \boldsymbol{p}_2$ 的像素位置为：

$$s_1 \boldsymbol{p}_1 = \boldsymbol{K}\boldsymbol{P}, \quad s_2 \boldsymbol{p}_2 = \boldsymbol{K}(\boldsymbol{R}\boldsymbol{P} + \boldsymbol{t}). \tag{7.1}$$

这里 $\boldsymbol{K}$ 为相机内参矩阵，$\boldsymbol{R}, \boldsymbol{t}$ 为两个坐标系的相机运动（如果我们愿意，也可以写成李代数形式）。如果使用齐次坐标，我们也可以把上式写成在乘以非零常数下成立的（up to a scale）等式[①]：

$$\boldsymbol{p}_1 = \boldsymbol{K}\boldsymbol{P}, \quad \boldsymbol{p}_2 = \boldsymbol{K}(\boldsymbol{R}\boldsymbol{P} + \boldsymbol{t}). \tag{7.2}$$

现在，取：

$$\boldsymbol{x}_1 = \boldsymbol{K}^{-1}\boldsymbol{p}_1, \quad \boldsymbol{x}_2 = \boldsymbol{K}^{-1}\boldsymbol{p}_2. \tag{7.3}$$

这里的 $\boldsymbol{x}_1, \boldsymbol{x}_2$ 是两个像素点的归一化平面上的坐标。代入上式，得：

$$\boldsymbol{x}_2 = \boldsymbol{R}\boldsymbol{x}_1 + \boldsymbol{t}. \tag{7.4}$$

两边同时左乘 $\boldsymbol{t}^\wedge$。回忆 $\wedge$ 的定义，这相当于两侧同时与 $\boldsymbol{t}$ 做外积：

$$\boldsymbol{t}^\wedge \boldsymbol{x}_2 = \boldsymbol{t}^\wedge \boldsymbol{R}\boldsymbol{x}_1. \tag{7.5}$$

然后，两侧同时左乘 $\boldsymbol{x}_2^T$：

$$\boldsymbol{x}_2^T \boldsymbol{t}^\wedge \boldsymbol{x}_2 = \boldsymbol{x}_2^T \boldsymbol{t}^\wedge \boldsymbol{R}\boldsymbol{x}_1. \tag{7.6}$$

观察等式左侧，$\boldsymbol{t}^\wedge \boldsymbol{x}_2$ 是一个与 $\boldsymbol{t}$ 和 $\boldsymbol{x}_2$ 都垂直的向量。把它再和 $\boldsymbol{x}_2$ 做内积时，将得到 0。因此，我们就得到了一个简洁的式子：

$$\boldsymbol{x}_2^T \boldsymbol{t}^\wedge \boldsymbol{R}\boldsymbol{x}_1 = 0. \tag{7.7}$$

重新代入 $\boldsymbol{p}_1, \boldsymbol{p}_2$，有：

$$\boldsymbol{p}_2^T \boldsymbol{K}^{-T} \boldsymbol{t}^\wedge \boldsymbol{R} \boldsymbol{K}^{-1} \boldsymbol{p}_1 = 0. \tag{7.8}$$

这两个式子都称为**对极约束**，它以形式简洁著名。它的几何意义是 $O_1, P, O_2$ 三者共面。对极约束中同时包含了平移和旋转。我们把中间部分记作两个矩阵：基础矩阵（Fundamental Matrix）$\boldsymbol{F}$ 和本质矩阵（Essential Matrix）$\boldsymbol{E}$，可以进一步简化对极约束：

$$\boldsymbol{E} = \boldsymbol{t}^\wedge \boldsymbol{R}, \quad \boldsymbol{F} = \boldsymbol{K}^{-T} \boldsymbol{E} \boldsymbol{K}^{-1}, \quad \boldsymbol{x}_2^T \boldsymbol{E} \boldsymbol{x}_1 = \boldsymbol{p}_2^T \boldsymbol{F} \boldsymbol{p}_1 = 0. \tag{7.9}$$

- **结论：**

对极约束给出了两个匹配点的空间位置关系。利用该关系，对相机位姿估计分为如下两步（实际中常用）：

（1）根据配对点的像素位置，求出$\boldsymbol{E}$或者$\boldsymbol{F}$。

（2）根据$\boldsymbol{E}$或$\boldsymbol{F}$，求出$\boldsymbol{R}$，$\boldsymbol{t}$。

## 2.1.1 八点法求 E

考虑一对匹配点，它们的归一化坐标为：$\boldsymbol{x}_1 = [u_1, v_1, 1]^T$, $\boldsymbol{x}_2 = [u_2, v_2, 1]^T$。根据对极约束，有:

$$\begin{pmatrix} u_1, v_1, 1 \end{pmatrix} \begin{pmatrix} e_1 & e_2 & e_3 \\ e_4 & e_5 & e_6 \\ e_7 & e_8 & e_9 \end{pmatrix} \begin{pmatrix} u_2 \\ v_2 \\ 1 \end{pmatrix} = 0. \tag{7.10}$$

我们把矩阵 $\boldsymbol{E}$ 展开，写成向量的形式：

$$\boldsymbol{e} = [e_1, e_2, e_3, e_4, e_5, e_6, e_7, e_8, e_9]^T,$$

那么对极约束可以写成与 $\boldsymbol{e}$ 有关的线性形式：

$$[u_1u_2, u_1v_2, u_1, v_1u_2, v_1v_2, v_1, u_2, v_2, 1] \cdot \boldsymbol{e} = 0. \tag{7.11}$$

同理，对于其它点对也有相同的表示。我们把所有点都放到一个方程中，变成线性方程组 ($u^i, v^i$ 表示第 $i$ 个特征点，以此类推)：

$$\begin{pmatrix} u_1^1u_2^1 & u_1^1v_2^1 & u_1^1 & v_1^1u_2^1 & v_1^1v_2^1 & v_1^1 & u_2^1 & v_2^1 & 1 \\ u_1^2u_2^2 & u_1^2v_2^2 & u_1^2 & v_1^2u_2^2 & v_1^2v_2^2 & v_1^2 & u_2^2 & v_2^2 & 1 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \\ u_1^8u_2^8 & u_1^8v_2^8 & u_1^8 & v_1^8u_2^8 & v_1^8v_2^8 & v_1^8 & u_2^8 & v_2^8 & 1 \end{pmatrix} \begin{pmatrix} e_1 \\ e_2 \\ e_3 \\ e_4 \\ e_5 \\ e_6 \\ e_7 \\ e_8 \\ e_9 \end{pmatrix} = 0. \tag{7.12}$$

这八个方程构成了一个线性方程组。它的系数矩阵由特征点位置构成，大小为 $8 \times 9$。$\boldsymbol{e}$ 位于该矩阵的零空间中。如果系数矩阵是满秩的（即秩为 8），那么它的零空间维数为 1，也就是 $\boldsymbol{e}$ 构成一条线。这与 $\boldsymbol{e}$ 的尺度等价性是一致的。如果八对匹配点组成的矩阵满足秩为 8 的条件，那么 $\boldsymbol{E}$ 的各元素就可由上述方程解得。

剩下的问题还有一个：根据线性方程解出的 $\boldsymbol{E}$，可能不满足 $\boldsymbol{E}$ 的内在性质——它的奇异值不一定为 $\sigma, \sigma, 0$ 的形式。这时，在做 SVD 时，我们会刻意地把 $\boldsymbol{\Sigma}$ 矩阵调整成上面的样子。通常的做法是，对八点法求得的 $\boldsymbol{E}$ 进行 SVD 分解后，会得到奇异值矩阵 $\boldsymbol{\Sigma} = \mathrm{diag}(\sigma_1, \sigma_2, \sigma_3)$，不妨设 $\sigma_1 \geq \sigma_2 \geq \sigma_3$。取：

$$\boldsymbol{E} = \boldsymbol{U}\mathrm{diag}(\frac{\sigma_1 + \sigma_2}{2}, \frac{\sigma_1 + \sigma_2}{2}, 0)\boldsymbol{V}^T. \tag{7.15}$$

这相当于是把求出来的矩阵投影到了 $\boldsymbol{E}$ 所在的流形上。当然，更简单的做法是将奇异值矩阵取成 $\mathrm{diag}(1, 1, 0)$，因为 $\boldsymbol{E}$ 具有尺度等价性，这样做也是合理的。

## 2.1.2 求位姿 R、t

接下来的问题是如何根据已经估得的本质矩阵 $\boldsymbol{E}$，恢复出相机的运动 $\boldsymbol{R}, \boldsymbol{t}$。这个过程是由奇异值分解（SVD）得到的。设 $\boldsymbol{E}$ 的 SVD 分解为：

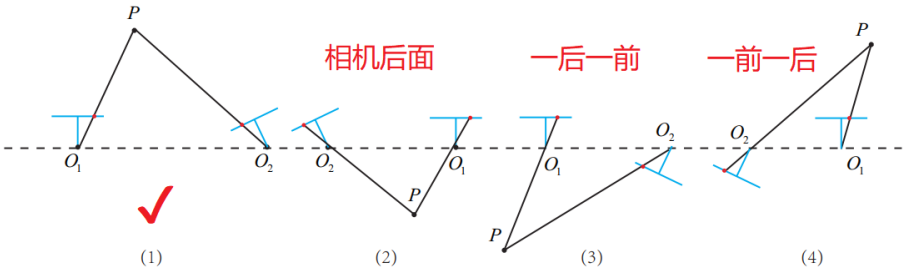
$$\boldsymbol{E} = \boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^T, \tag{7.13}$$

其中 $\boldsymbol{U}, \boldsymbol{V}$ 为正交阵，$\boldsymbol{\Sigma}$ 为奇异值矩阵。根据 $\boldsymbol{E}$ 的内在性质，我们知道 $\boldsymbol{\Sigma} = diag(\sigma, \sigma, 0)$。在 SVD 分解中，对于任意一个 $\boldsymbol{E}$，存在两个可能的 $\boldsymbol{t}, \boldsymbol{R}$ 与它对应：

$$\begin{aligned} \boldsymbol{t}_1^\wedge &= \boldsymbol{U}\boldsymbol{R}_Z\left(\frac{\pi}{2}\right)\boldsymbol{\Sigma}\boldsymbol{U}^T, \quad \boldsymbol{R}_1 = \boldsymbol{U}\boldsymbol{R}_Z^T\left(\frac{\pi}{2}\right)\boldsymbol{V}^T \\ \boldsymbol{t}_2^\wedge &= \boldsymbol{U}\boldsymbol{R}_Z\left(-\frac{\pi}{2}\right)\boldsymbol{\Sigma}\boldsymbol{U}^T, \quad \boldsymbol{R}_2 = \boldsymbol{U}\boldsymbol{R}_Z^T\left(-\frac{\pi}{2}\right)\boldsymbol{V}^T. \end{aligned} \tag{7.14}$$

其中 $\boldsymbol{R}_Z\left(\frac{\pi}{2}\right)$ 表示沿 $Z$ 轴旋转 90 度得到的旋转矩阵。同时，由于 $-\boldsymbol{E}$ 和 $\boldsymbol{E}$ 等价，所以对任意一个 $\boldsymbol{t}$ 取负号，也会得到同样的结果。因此，从 $\boldsymbol{E}$ 分解到 $\boldsymbol{t}, \boldsymbol{R}$ 时，一共存在四个可能的解。

图 7-8 形象地显示了分解本质矩阵得到的四个解。我们已知空间点在相机（蓝色线）上的投影（红点），想要求解相机的运动。在保持红点不变的情况下，可以画出四种可能的情况，不过幸运的是，只有第一种解中，$P$ 在两个相机中都具有正的深度。因此，只要把任意一点代入四种解中，检测该点在两个相机下的深度，就可以确定哪个解是正确的了。




## 2.2 单应矩阵

若场景中的特征点都落在同一平面上（无人机俯视相机，或扫地机顶视相机中常见），则可以通过单应性来进行运动估计。

- **求单应矩阵 H：**

单应矩阵通常描述处于共同平面上的一些点，在两张图像之间的变换关系。考虑在图像 $I_1$ 和 $I_2$ 有一对匹配好的特征点 $p_1$ 和 $p_2$。这些特征点落在某平面上。设这个平面满足方程：

$$\boldsymbol{n}^T\boldsymbol{P} + d = 0. \tag{7.16}$$

稍加整理，得：

$$-\frac{\boldsymbol{n}^T\boldsymbol{P}}{d} = 1. \tag{7.17}$$

然后，回顾本开头的式 (7.1)，得：

$$\begin{aligned}\boldsymbol{p}_2 &= \boldsymbol{K}(\boldsymbol{R}\boldsymbol{P} + \boldsymbol{t}) \\ &= \boldsymbol{K}\left(\boldsymbol{R}\boldsymbol{P} + \boldsymbol{t}\cdot(-\frac{\boldsymbol{n}^T\boldsymbol{P}}{d})\right) \\ &= \boldsymbol{K}\left(\boldsymbol{R} - \frac{\boldsymbol{t}\boldsymbol{n}^T}{d}\right)\boldsymbol{P} \\ &= \boldsymbol{K}\left(\boldsymbol{R} - \frac{\boldsymbol{t}\boldsymbol{n}^T}{d}\right)\boldsymbol{K}^{-1}\boldsymbol{p}_1.\end{aligned}$$

于是，我们得到了一个直接描述图像坐标 $\boldsymbol{p}_1$ 和 $\boldsymbol{p}_2$ 之间的变换，把中间这部分记为 $\boldsymbol{H}$，于是

$$\boldsymbol{p}_2 = \boldsymbol{H}\boldsymbol{p}_1. \tag{7.18}$$

它的定义与旋转、平移以及平面的参数有关。与基础矩阵 $\boldsymbol{F}$ 类似，单应矩阵 $\boldsymbol{H}$ 也是一个 $3\times 3$ 的矩阵，求解时的思路也和 $\boldsymbol{F}$ 类似，同样地可以先根据匹配点计算 $\boldsymbol{H}$，然后将它分解以计算旋转和平移。把上式展开，得：

$$\begin{pmatrix}u_2\\ v_2\\ 1\end{pmatrix} = \begin{pmatrix}h_1 & h_2 & h_3\\ h_4 & h_5 & h_6\\ h_7 & h_8 & h_9\end{pmatrix}\begin{pmatrix}u_1\\ v_1\\ 1\end{pmatrix}. \tag{7.19}$$

请注意这里的等号是在非零因子下成立的。我们在实际处理中，通常乘以一个非零因子使得 $h_9 = 1$（在它取非零值时）。然后根据第三行，去掉这个非零因子，于是有：

$$u_2 = \frac{h_1u_1 + h_2v_1 + h_3}{h_7u_1 + h_8v_1 + h_9}$$

$$v_2 = \frac{h_4u_1 + h_5v_1 + h_6}{h_7u_1 + h_8v_1 + h_9}.$$

整理得：

$$h_1u_1 + h_2v_1 + h_3 - h_7u_1u_2 - h_8v_1u_2 = u_2$$

$$h_4u_1 + h_5v_1 + h_6 - h_7u_1v_2 - h_8v_1v_2 = v_2.$$

这样一组匹配点对就可以构造出两项约束（事实上有三个约束，但是因为线性相关，只取前两个），于是自由度为 8 的单应矩阵可以通过 4 对匹配特征点算出（注意：这些特征点不能有三点共线的情况），即求解以下的线性方程组（当 $h_9 = 0$ 时，右侧为零）：

$$\begin{pmatrix}
u_1^1 & v_1^1 & 1 & 0 & 0 & 0 & -u_1^1u_2^1 & -v_1^1u_2^1\\
0 & 0 & 0 & u_1^1 & v_1^1 & 1 & -u_1^1v_2^1 & -v_1^1v_2^1\\
u_1^2 & v_1^2 & 1 & 0 & 0 & 0 & -u_1^2u_2^2 & -v_1^2u_2^2\\
0 & 0 & 0 & u_1^2 & v_1^2 & 1 & -u_1^2v_2^2 & -v_1^2v_2^2\\
u_1^3 & v_1^3 & 1 & 0 & 0 & 0 & -u_1^3u_2^3 & -v_1^3u_2^3\\
0 & 0 & 0 & u_1^3 & v_1^3 & 1 & -u_1^3v_2^3 & -v_1^3v_2^3\\
u_1^4 & v_1^4 & 1 & 0 & 0 & 0 & -u_1^4u_2^4 & -v_1^4u_2^4\\
0 & 0 & 0 & u_1^4 & v_1^4 & 1 & -u_1^4v_2^4 & -v_1^4v_2^4
\end{pmatrix}\begin{pmatrix}h_1\\ h_2\\ h_3\\ h_4\\ h_5\\ h_6\\ h_7\\ h_8\end{pmatrix} = \begin{pmatrix}u_2^1\\ v_2^1\\ u_2^2\\ v_2^2\\ u_2^3\\ v_2^3\\ u_2^4\\ v_2^4\end{pmatrix}. \tag{7.20}$$

- **求位姿 R、t：**

  类似本质矩阵，将单应矩阵分解得到位姿。

  方法：数值法、解析法。

## 2.3 三角测量

得到运动后，下一步需要用相机的运动估计特征点的空间位置。

三角测量：通过在两处观察同一个点的夹角，确定该点的距离。

和上一节类似，考虑图像 $I_1$ 和 $I_2$，以左图为参考，右图的变换矩阵为 $\boldsymbol{T}$。相机光心为 $O_1$ 和 $O_2$。在 $I_1$ 中有特征点 $p_1$，对应 $I_2$ 中有特征点 $p_2$。理论上直线 $O_1p_1$ 与 $O_2p_2$ 在场景中会相交于一点 $P$，该点即是两个特征点所对应的地图点在三维场景中的位置。然而由于噪声的影响，这两条直线往往无法相交。因此，（又）可以通过最二小乘去求解。

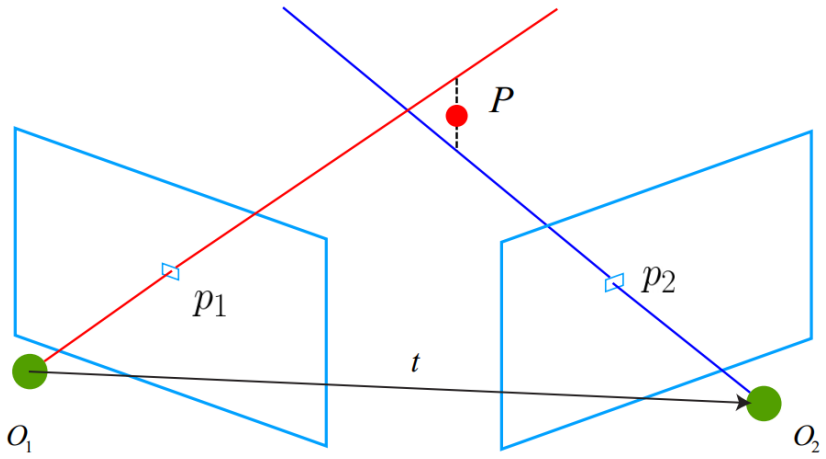
按照对极几何中的定义，设 $\boldsymbol{x}_1, \boldsymbol{x}_2$ 为两个特征点的归一化坐标，那么它们满足：

$$s_1\boldsymbol{x}_1 = s_2\boldsymbol{R}\boldsymbol{x}_2 + \boldsymbol{t}. \tag{7.24}$$

现在我们已经知道了 $\boldsymbol{R}, \boldsymbol{t}$，想要求解的是两个特征点的深度 $s_1, s_2$。当然这两个深度是可以分开求的，比方说先来看 $s_2$。如果我要算 $s_2$，那么先对上式两侧左乘一个 $\boldsymbol{x}_1^\wedge$，得：

$$s_1\boldsymbol{x}_1^\wedge\boldsymbol{x}_1 = 0 = s_2\boldsymbol{x}_1^\wedge\boldsymbol{R}\boldsymbol{x}_2 + \boldsymbol{x}_1^\wedge\boldsymbol{t}. \tag{7.25}$$

该式左侧为零，右侧可看成 $s_2$ 的一个方程，可以根据它直接求得 $s_2$。有了 $s_2$，$s_1$ 也非常容易求出。于是，我们就得到了两个帧下的点的深度，确定了它们的空间坐标。当然，由于噪声的存在，我们估得的 $\boldsymbol{R}, \boldsymbol{t}$，不一定精确使式（7.24）为零，所以更常见的做法求最小二乘解而不是零解。




## 2.4 存在问题与特殊情况

- **尺度不确定性：**

对 $t$ 长度的归一化，直接导致了**单目视觉的尺度不确定性（Scale Ambiguity）**。例如，程序中输出的 $t$ 第一维约 0.822。这个 0.822 究竟是指 0.822 米呢，还是 0.822 厘米呢，我们是没法确定的。因为对 $t$ 乘以任意比例常数后，对极约束依然是成立的。换言之，在单目 SLAM 中，对轨迹和地图同时缩放任意倍数，我们得到的图像依然是一样的。这在第二讲中就已经给读者介绍过了。 不确定平移量具体是多少

在单目视觉中，我们对两张图像的 $t$ 归一化，相当于**固定了尺度**。虽然我们不知道它的实际长度为多少，但我们以这时的 $t$ 为单位 1，计算相机运动和特征点的 3D 位置。这被称为单目 SLAM 的**初始化**。在初始化之后，就可以用 3D-2D 来计算相机运动了。初始化之后的轨迹和地图的单位，就是初始化时固定的尺度。因此，单目 SLAM 有一步不可避免的**初始化**。初始化的两张图像必须有一定程度的平移，而后的轨迹和地图都将以此步的平移为单位。

除了对 $t$ 进行归一化之外，另一种方法是令初始化时所有的特征点平均深度为 1，也可以固定一个尺度。相比于令 $t$ 长度为 1 的做法，把特征点深度归一化可以控制场景的规模大小，使计算在数值上更稳定些。不过这并没有理论上的差别。

- **初始化的纯旋转问题：**

从 $E$ 分解到 $R, t$ 的过程中，如果相机发生的是纯旋转，导致 $t$ 为零，那么，得到的 $E$ 也将为零，这将导致我们无从求解 $R$。不过，此时我们可以依靠 $H$ 求取旋转，但仅有旋转时，我们无法用三角测量估计特征点的空间位置（这将在下文提到），于是，另一个结论是，**单目初始化不能只有纯旋转，必须要有一定程度的平移**。如果没有平移，单目将无法初始化。在实践当中，如果初始化时平移太小，会使得位姿求解与三角化结果不稳定，从而导致失败。相对的，如果把相机左右移动而不是原地旋转，就容易让单目 SLAM 初始化。因而有经验的 SLAM 研究人员，在单目 SLAM 情况下，经常选择让相机进行左右平移以顺利地进行初始化。

- **多于 8 对点的情况：**

当给定的点数多于八对时（比如例程找到了 79 对匹配），我们可以计算一个最小二乘解。回忆式（7.12）中线性化后的对极约束，我们把左侧的系数矩阵记为 $A$：

$$Ae = 0. \tag{7.22}$$

对于八点法，$A$ 的大小为 $8 \times 9$。如果给定的匹配点多于 8，该方程构成一个超定方程，即不一定存在 $e$ 使得上式成立。因此，可以通过最小化一个二次型来求：

$$\min_{e} \|Ae\|_2^2 = \min_{e} e^T A^T A e. \tag{7.23}$$

于是就求出了在最小二乘意义下的 $E$ 矩阵。不过，当可能存在误匹配的情况时，我们会更倾向于使用**随机采样一致性（Random Sample Concensus, RANSAC）**来求，而不是最小二乘。RANSAC 是一种通用的做法，适用于很多带错误数据的情况，可以处理带有错误匹配的数据。

# 三. 3D-2D：PnP

**PnP**：已知 n 个 3D 空间点（世界坐标）及其投影位置（像素坐标）时，如何估计相机位姿。

**应用场景：**（1）双目或 RGB-D，直接使用 PnP；（2）单目，先用对极几何进行初始化，再用 PnP。

**方法：**直接线性变换（DLT）、P3P、EPnP、Bundle Adjustment。通常先使用 P3P/EPnP 等方法估计相机位姿，然后构建最小二乘优化问题对估计值进行调整（Bundle Adjustment）。

## 3.1 直接线性变换（DLT）

考虑某个空间点 $P$，它的齐次坐标为 $\boldsymbol{P} = (X, Y, Z, 1)^T$。在图像 $I_1$ 中，投影到特征点 $\boldsymbol{x}_1 = (u_1, v_1, 1)^T$（以归一化平面齐次坐标表示）。此时相机的位姿 $\boldsymbol{R}, \boldsymbol{t}$ 是未知的。与单应矩阵的求解类似，我们定义增广矩阵 $[\boldsymbol{R}|\boldsymbol{t}]$ 为一个 $3 \times 4$ 的矩阵，包含了旋转与平移信息[1]。我们把它的展开形式列写如下：

$$s \begin{pmatrix} u_1 \\ v_1 \\ 1 \end{pmatrix} = \begin{pmatrix} t_1 & t_2 & t_3 & t_4 \\ t_5 & t_6 & t_7 & t_8 \\ t_9 & t_{10} & t_{11} & t_{12} \end{pmatrix} \begin{pmatrix} X \\ Y \\ Z \\ 1 \end{pmatrix}. \tag{7.26}$$

用最后一行把 $s$ 消去，得到两个约束：

$$u_1 = \frac{t_1 X + t_2 Y + t_3 Z + t_4}{t_9 X + t_{10} Y + t_{11} Z + t_{12}} \quad v_1 = \frac{t_5 X + t_6 Y + t_7 Z + t_8}{t_9 X + t_{10} Y + t_{11} Z + t_{12}}.$$

为了简化表示，定义 $\boldsymbol{T}$ 的行向量：

$$\boldsymbol{t}_1 = (t_1, t_2, t_3, t_4)^T, \boldsymbol{t}_2 = (t_5, t_6, t_7, t_8)^T, \boldsymbol{t}_3 = (t_9, t_{10}, t_{11}, t_{12})^T,$$

于是有：

和

$$\begin{aligned} \boldsymbol{t}_1^T \boldsymbol{P} - \boldsymbol{t}_3^T \boldsymbol{P} u_1 = 0, \\ \boldsymbol{t}_2^T \boldsymbol{P} - \boldsymbol{t}_3^T \boldsymbol{P} v_1 = 0. \end{aligned}$$

请注意 $\boldsymbol{t}$ 是待求的变量，可以看到每个特征点提供了两个关于 $\boldsymbol{t}$ 的线性约束。假设一共有 $N$ 个特征点，可以列出线性方程组：

$$\begin{pmatrix} \boldsymbol{P}_1^T & 0 & -u_1 \boldsymbol{P}_1^T \\ 0 & \boldsymbol{P}_1^T & -v_1 \boldsymbol{P}_1^T \\ \vdots & \vdots & \vdots \\ \boldsymbol{P}_N^T & 0 & -u_N \boldsymbol{P}_N^T \\ 0 & \boldsymbol{P}_N^T & -v_N \boldsymbol{P}_N^T \end{pmatrix} \begin{pmatrix} \boldsymbol{t}_1 \\ \boldsymbol{t}_2 \\ \boldsymbol{t}_3 \end{pmatrix} = 0. \tag{7.27}$$

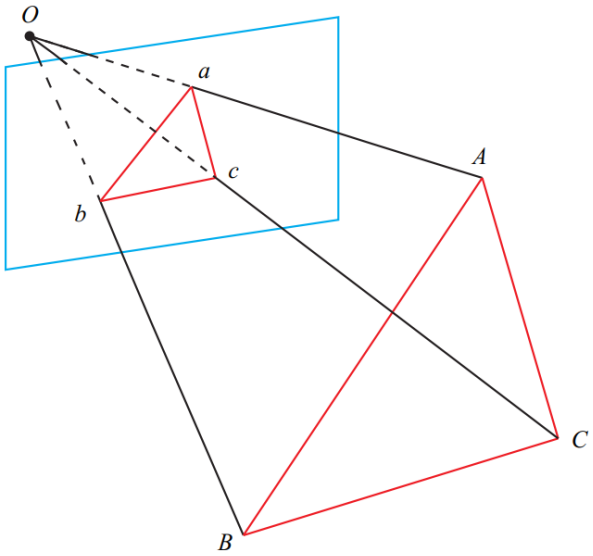
由于 $\boldsymbol{t}$ 一共有 12 维，因此最少通过六对匹配点，即可实现矩阵 $\boldsymbol{T}$ 的线性求解，这种方法（也）称为直接线性变换（Direct Linear Transform，DLT）。当匹配点大于六对时，（又）可以使用 SVD 等方法对超定方程求最小二乘解。

在 DLT 求解中，我们直接将 $\boldsymbol{T}$ 矩阵看成了 12 个未知数，忽略了它们之间的联系。因为旋转矩阵 $\boldsymbol{R} \in SO(3)$，用 DLT 求出的解不一定满足该约束，它是一个一般矩阵。平移向量比较好办，它属于向量空间。对于旋转矩阵 $\boldsymbol{R}$，我们必须针对 DLT 估计的 $\boldsymbol{T}$ 的左边 $3 \times 3$ 的矩阵块，寻找一个最好的旋转矩阵对它进行近似。这可以由 QR 分解完成 [3, 48]，相当于把结果从矩阵空间重新投影到 $SE(3)$ 流形上，转换成旋转和平移两部分。

需要解释的是，我们这里的 $\boldsymbol{x}_1$ 使用了归一化平面坐标，去掉了内参矩阵 $\boldsymbol{K}$ 的影响——这是因为内参 $\boldsymbol{K}$ 在 SLAM 中通常假设为已知。如果内参未知，那么我们也能用 PnP 去估计 $\boldsymbol{K}, \boldsymbol{R}, \boldsymbol{t}$ 三个量。然而由于未知量的增多，效果会差一些。

## 3.2 P3P

- **过程：**



P3P 需要利用给定的三个点的几何关系。它的输入数据为三对 3D-2D 匹配点。记 3D 点为 $A, B, C$，2D 点为 $a, b, c$，其中小写字母代表的点为大写字母在相机成像平面上的投影，如图 7-11 所示。此外，P3P 还需要使用一对验证点，以从可能的解出选出正确的那一个（类似于对极几何情形）。记验证点对为 $D-d$，相机光心为 $O$。请注意，我们知道的是 $A, B, C$ 在**世界坐标系中的坐标**，而不是**在相机坐标系中的坐标**。一旦 3D 点在相机坐标系下的坐标能够算出，我们就得到了 3D-3D 的对应点，把 PnP 问题转换为了 ICP 问题。

来考虑 $Oab$ 和 $OAB$ 的关系。利用余弦定理，有：

$$OA^2 + OB^2 - 2OA \cdot OB \cdot \cos\langle a, b\rangle = AB^2. \tag{7.29}$$

对于其他两个三角形亦有类似性质，于是有：

$$\begin{aligned} OA^2 + OB^2 - 2OA \cdot OB \cdot \cos\langle a, b\rangle &= AB^2 \\ OB^2 + OC^2 - 2OB \cdot OC \cdot \cos\langle b, c\rangle &= BC^2 \\ OA^2 + OC^2 - 2OA \cdot OC \cdot \cos\langle a, c\rangle &= AC^2. \end{aligned} \tag{7.30}$$

对上面三式全体除以 $OC^2$，并且记 $x = OA/OC, y = OB/OC$，得：

$$\begin{aligned} x^2 + y^2 - 2xy\cos\langle a, b\rangle &= AB^2/OC^2 \\ y^2 + 1^2 - 2y\cos\langle b, c\rangle &= BC^2/OC^2 \\ x^2 + 1^2 - 2x\cos\langle a, c\rangle &= AC^2/OC^2. \end{aligned} \tag{7.31}$$

记 $v = AB^2/OC^2, uv = BC^2/OC^2, wv = AC^2/OC^2$，有：

$$\begin{aligned} x^2 + y^2 - 2xy\cos\langle a, b\rangle - v &= 0 \\ y^2 + 1^2 - 2y\cos\langle b, c\rangle - uv &= 0 \\ x^2 + 1^2 - 2x\cos\langle a, c\rangle - wv &= 0. \end{aligned} \tag{7.32}$$

我们可以把第一个式子中的 $v$ 放到等式一边，并代入第 2，3 两式，得：

$$\begin{aligned} (1-u)\, y^2 - ux^2 - \cos\langle b, c\rangle\, y + 2uxy\cos\langle a, b\rangle + 1 &= 0 \\ (1-w)\, x^2 - wy^2 - \cos\langle a, c\rangle\, x + 2wxy\cos\langle a, b\rangle + 1 &= 0. \end{aligned} \tag{7.33}$$

注意这些方程中的已知量和未知量。由于我们知道 2D 点的图像位置，三个余弦角 $\cos\langle a, b\rangle, \cos\langle b, c\rangle, \cos\langle a, c\rangle$ 是已知的。同时，$u = BC^2/AB^2, w = AC^2/AB^2$ 可以通过 $A, B, C$ 在世界坐标系下的坐标算出，变换到相机坐标系下之后，并不改变这个比值。该式中的 $x, y$ 是未知的，随着相机移动会发生变化。因此，该方程组是关于 $x, y$ 的一个二元二次方程（多项式方程）。解析地求解该方程组是一个复杂的过程，需要用吴消元法。

- **提取固定数量的特征：**

从 P3P 的原理上可以看出，为了求解 PnP，我们利用了三角形相似性质，求解投影点 $a, b, c$ 在相机坐标系下的 3D 坐标，最后把问题转换成一个 3D 到 3D 的位姿估计问题。后文将看到，带有匹配信息的 3D-3D 位姿求解非常容易，所以这种思路是非常有效的。其他的一些方法，例如 EPnP，亦采用了这种思路。然而，P3P 也存在着一些问题：

1. P3P 只利用三个点的信息。当给定的配对点多于 3 组时，难以利用更多的信息。
2. 如果 3D 点或 2D 点受噪声影响，或者存在误匹配，则算法失效。

## 3.3 Bundle Adjustment

- **重投影误差：**

DLT、P3P、EPnP 等线性方法，先求相机位姿，再求空间点位置。而非线性优化则是把它们都看成优化变量，放在一起优化，可用于对 PnP 或 ICP 给出的结果进行优化。

考虑 $n$ 个三维空间点 $P$ 和它们的投影 $p$，我们希望计算相机的位姿 $\boldsymbol{R}, \boldsymbol{t}$，它的李代数表示为 $\boldsymbol{\xi}$。假设某空间点坐标为 $\boldsymbol{P}_i = [X_i, Y_i, Z_i]^T$，其投影的像素坐标为 $\boldsymbol{u}_i = [u_i, v_i]^T$。根据第五章的内容，像素位置与空间点位置的关系如下：

$$s_i \begin{bmatrix} u_i \\ v_i \\ 1 \end{bmatrix} = \boldsymbol{K} \exp(\boldsymbol{\xi}^\wedge) \begin{bmatrix} X_i \\ Y_i \\ Z_i \\ 1 \end{bmatrix}. \tag{7.34}$$

除了用 $\boldsymbol{\xi}$ 为李代数表示的相机姿态之外，别的都和前面的定义保持一致。写成矩阵形式就是：

$$s_i \boldsymbol{u}_i = \boldsymbol{K} \exp(\boldsymbol{\xi}^\wedge) \boldsymbol{P}_i.$$

请读者脑补中间隐含着的齐次坐标到非齐次的转换，否则按矩阵的乘法来说，维度是不对的[①]。现在，由于相机位姿未知以及观测点的噪声，该等式存在一个误差。因此，我们把误差求和，构建最小二乘问题，然后寻找最好的相机位姿，使它最小化：

目标：

$$\boldsymbol{\xi}^* = \arg\min_{\boldsymbol{\xi}} \frac{1}{2} \sum_{i=1}^{n} \left\| \boldsymbol{u}_i - \frac{1}{s_i} \boldsymbol{K} \exp(\boldsymbol{\xi}^\wedge) \boldsymbol{P}_i \right\|_2^2. \tag{7.35}$$

该问题的误差项，是将像素坐标（观测到的投影位置）与 3D 点按照当前估计的位姿进行投影得到的位置相比较得到的误差，所以称之为**重投影误差**。使用齐次坐标时，这个误差有 3 维。不过，由于 $\boldsymbol{u}$ 最后一维为 1，该维度的误差一直为零，因而我们更多时候使用非齐次坐标，于是误差就只有 2 维了。如图 7-12 所示，我们通过特征匹配，知道了 $p_1$ 和 $p_2$ 是同一个空间点 $P$ 的投影，但是我们不知道相机的位姿。在初始值中，$P$ 的投影 $\hat{p}_2$ 与实际的 $p_2$ 之间有一定的距离。于是我们调整相机的位姿，使得这个距离变小。不过，由于这个调整需要考虑很多个点，所以最后每个点的误差通常都不会精确为零。

最小二乘优化问题已经在第六讲介绍过了。使用李代数，可以构建无约束的优化问题，很方便地通过 G-N, L-M 等优化算法进行求解。不过，在使用 G-N 和 L-M 之前，我们需要知道每个误差项关于优化变量的导数，也就是**线性化**：

高斯牛顿法　列文伯格-马尔夸特法

关键：求雅可比 J

$$\boldsymbol{e}(\boldsymbol{x} + \Delta\boldsymbol{x}) \approx \boldsymbol{e}(\boldsymbol{x}) + \boldsymbol{J}\Delta\boldsymbol{x}. \tag{7.36}$$

这里的 $\boldsymbol{J}$ 的形式是值得讨论的，甚至可以说是关键所在。我们固然可以使用数值导数，但如果能够推导解析形式时，我们会优先考虑解析导数。现在，当 $\boldsymbol{e}$ 为像素坐标误差（2 维），$\boldsymbol{x}$ 为相机位姿（6 维）时，$\boldsymbol{J}$ 将是一个 $2 \times 6$ 的矩阵。我们来推导 $\boldsymbol{J}$ 的形式。

- **优化位姿：**

(1) 定义中间变量：$$\boldsymbol{P}' = (\exp(\boldsymbol{\xi}^\wedge)\boldsymbol{P})_{1:3} = [X', Y', Z']^T. \tag{7.37}$$

那么，相机投影模型相对于 $\boldsymbol{P}'$ 则为：

$$s\boldsymbol{u} = \boldsymbol{K}\boldsymbol{P}'. \tag{7.38}$$

展开之：

$$\begin{bmatrix} su \\ sv \\ s \end{bmatrix} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} X' \\ Y' \\ Z' \end{bmatrix}. \tag{7.39}$$

利用第 3 行消去 $s$（实际上就是 $\boldsymbol{P}'$ 的距离），得：

$$u = f_x \frac{X'}{Z'} + c_x, \quad v = f_y \frac{Y'}{Z'} + c_y. \tag{7.40}$$

这与之前讲的相机模型是一致的。当我们求误差时，可以把这里的 $u, v$ 与实际的测量值比较，求差。在定义了中间变量后，我们对 $\boldsymbol{\xi}^\wedge$ 左乘扰动量 $\delta\boldsymbol{\xi}$，然后考虑 $\boldsymbol{e}$ 的变化关于扰动量的导数。利用链式法则，可以列写如下：(2)

$$\frac{\partial \boldsymbol{e}}{\partial \delta\boldsymbol{\xi}} = \lim_{\delta\boldsymbol{\xi}\to 0} \frac{\boldsymbol{e}(\delta\boldsymbol{\xi} \oplus \boldsymbol{\xi})}{\delta\boldsymbol{\xi}} = \frac{\partial \boldsymbol{e}}{\partial \boldsymbol{P}'} \frac{\partial \boldsymbol{P}'}{\partial \delta\boldsymbol{\xi}}. \tag{7.41}$$

这里的 $\oplus$ 指李代数上的左乘扰动。第一项是误差关于投影点的导数，在式（7.40）已经列出了变量之间的关系，易得：

① $$\frac{\partial \boldsymbol{e}}{\partial \boldsymbol{P}'} = -\begin{bmatrix} \frac{\partial u}{\partial X'} & \frac{\partial u}{\partial Y'} & \frac{\partial u}{\partial Z'} \\ \frac{\partial v}{\partial X'} & \frac{\partial v}{\partial Y'} & \frac{\partial v}{\partial Z'} \end{bmatrix} = -\begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} \end{bmatrix}. \tag{7.42}$$

而第二项为变换后的点关于李代数的导数，根据在4.3.5中的推导，得：

$$\frac{\partial (\boldsymbol{T}\boldsymbol{P})}{\partial \delta\boldsymbol{\xi}} = (\boldsymbol{T}\boldsymbol{P})^\odot = \begin{bmatrix} \boldsymbol{I} & -\boldsymbol{P}'^\wedge \\ \boldsymbol{0}^T & \boldsymbol{0}^T \end{bmatrix}. \tag{7.43}$$

而在 $\boldsymbol{P}'$ 的定义中，我们取出了前三维，于是得：

② $$\frac{\partial \boldsymbol{P}'}{\partial \delta\boldsymbol{\xi}} = [\boldsymbol{I}, -\boldsymbol{P}'^\wedge]. \tag{7.44}$$

将这两项相乘，就得到了 $2 \times 6$ 的雅可比矩阵：

$$\frac{\partial \boldsymbol{e}}{\partial \delta\boldsymbol{\xi}} = -\begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} & -\frac{f_x X' Y'}{Z'^2} & f_x + \frac{f_x X^2}{Z'^2} & -\frac{f_x Y'}{Z'} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} & -f_y - \frac{f_y Y'^2}{Z'^2} & \frac{f_y X' Y'}{Z'^2} & \frac{f_y X'}{Z'} \end{bmatrix}. \tag{7.45}$$

这个雅可比矩阵描述了重投影误差关于相机位姿李代数的一阶变化关系。我们保留了前面的负号，因为这是由于误差是由**观测值减预测值**定义的。它当然也可反过来，定义成“预测减观测”的形式。在那种情况下，只要去掉前面的负号即可。此外，如果 $\mathfrak{se}(3)$ 的定义方式是旋转在前，平移在后时，只要把这个矩阵的前三列与后三列对调即可。

- **优化特征点空间位置：**

另一方面，除了优化位姿，我们还希望优化特征点的空间位置。因此，需要讨论 $\boldsymbol{e}$ 关于空间点 $\boldsymbol{P}$ 的导数。所幸这个导数矩阵相对来说容易一些。仍利用链式法则，有：

$$\frac{\partial \boldsymbol{e}}{\partial \boldsymbol{P}} = \frac{\partial \boldsymbol{e}}{\partial \boldsymbol{P}'} \frac{\partial \boldsymbol{P}'}{\partial \boldsymbol{P}}. \tag{7.46}$$

①第一项已在前面推导了，第二项，按照定义

② $$\boldsymbol{P}' = \exp(\boldsymbol{\xi}^\wedge)\boldsymbol{P} = \boldsymbol{R}\boldsymbol{P} + \boldsymbol{t}.$$

我们发现 $\boldsymbol{P}'$ 对 $\boldsymbol{P}$ 求导后只剩下 $\boldsymbol{R}$。于是

$$\frac{\partial \boldsymbol{e}}{\partial \boldsymbol{P}} = -\begin{bmatrix} \frac{f_x}{Z'} & 0 & -\frac{f_x X'}{Z'^2} \\ 0 & \frac{f_y}{Z'} & -\frac{f_y Y'}{Z'^2} \end{bmatrix} \boldsymbol{R}. \tag{7.47}$$

# 四. 3D-3D：ICP

**应用场景：**已知一组配对好的 3D 点（如两个匹配好的 RGB-D 图像），估计位姿。

**方法：**迭代最近点（Iterative Closest Point, ICP）。

最后，我们来介绍 3D-3D 的位姿估计问题。假设我们有一组配对好的 3D 点（比如我们对两个 RGB-D 图像进行了匹配）：

$$\boldsymbol{P} = \{\boldsymbol{p}_1, \ldots, \boldsymbol{p}_n\}, \quad \boldsymbol{P}' = \{\boldsymbol{p}'_1, \ldots, \boldsymbol{p}'_n\},$$

现在，想要找一个欧氏变换 $\boldsymbol{R}, \boldsymbol{t}$，使得：

$$\forall i, \boldsymbol{p}_i = \boldsymbol{R}\boldsymbol{p}'_i + \boldsymbol{t}.$$

## 4.1 SDV 方法

- **SVD 法推导：**

首先我们看以 SVD 为代表的代数方法。根据前面描述的 ICP 问题，我们先定义第 $i$ 对点的误差项：

$$\boldsymbol{e}_i = \boldsymbol{p}_i - (\boldsymbol{R}\boldsymbol{p}_i' + \boldsymbol{t}). \tag{7.48}$$

然后，构建最小二乘问题，求使误差平方和达到极小的 $\boldsymbol{R}, \boldsymbol{t}$：

SVD目标：

$$\min_{\boldsymbol{R},\boldsymbol{t}} J = \frac{1}{2}\sum_{i=1}^{n} \|(\boldsymbol{p}_i - (\boldsymbol{R}\boldsymbol{p}_i' + \boldsymbol{t}))\|_2^2. \tag{7.49}$$

下面我们来推导它的求解方法。首先，定义两组点的质心：

$$\boldsymbol{p} = \frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{p}_i), \quad \boldsymbol{p}' = \frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{p}_i'). \tag{7.50}$$

请注意质心是没有下标的。随后，在误差函数中，我们作如下的处理：

$$\begin{aligned}
\frac{1}{2}\sum_{i=1}^{n} \|\boldsymbol{p}_i - (\boldsymbol{R}\boldsymbol{p}_i' + \boldsymbol{t})\|^2 &= \frac{1}{2}\sum_{i=1}^{n} \|\boldsymbol{p}_i - \boldsymbol{R}\boldsymbol{p}_i' - \boldsymbol{t} - \boldsymbol{p} + \boldsymbol{R}\boldsymbol{p}' + \boldsymbol{p} - \boldsymbol{R}\boldsymbol{p}'\|^2 \\
&= \frac{1}{2}\sum_{i=1}^{n} \|(\boldsymbol{p}_i - \boldsymbol{p} - \boldsymbol{R}(\boldsymbol{p}_i' - \boldsymbol{p}')) + (\boldsymbol{p} - \boldsymbol{R}\boldsymbol{p}' - \boldsymbol{t})\|^2 \\
&= \frac{1}{2}\sum_{i=1}^{n} (\|\boldsymbol{p}_i - \boldsymbol{p} - \boldsymbol{R}(\boldsymbol{p}_i' - \boldsymbol{p}')\|^2 + \|\boldsymbol{p} - \boldsymbol{R}\boldsymbol{p}' - \boldsymbol{t}\|^2 + \\
&\quad 2(\boldsymbol{p}_i - \boldsymbol{p} - \boldsymbol{R}(\boldsymbol{p}_i' - \boldsymbol{p}'))^T (\boldsymbol{p} - \boldsymbol{R}\boldsymbol{p}' - \boldsymbol{t})).
\end{aligned}$$

注意到交叉项部分中，$(\boldsymbol{p}_i - \boldsymbol{p} - \boldsymbol{R}(\boldsymbol{p}_i' - \boldsymbol{p}'))$ 在求和之后是为零的，因此优化目标函数可以简化为：

$$\min_{\boldsymbol{R},\boldsymbol{t}} J = \frac{1}{2}\sum_{i=1}^{n} \|\boldsymbol{p}_i - \boldsymbol{p} - \boldsymbol{R}(\boldsymbol{p}_i' - \boldsymbol{p}')\|^2 + \|\boldsymbol{p} - \boldsymbol{R}\boldsymbol{p}' - \boldsymbol{t}\|^2. \tag{7.51}$$

仔细观察左右两项，我们发现左边只和旋转矩阵 $\boldsymbol{R}$ 相关，而右边既有 $\boldsymbol{R}$ 也有 $\boldsymbol{t}$，但只和质心相关。只要我们获得了 $\boldsymbol{R}$，令第二项为零就能得到 $\boldsymbol{t}$。

- **总结：**

1. 计算两组点的质心位置 $\boldsymbol{p}, \boldsymbol{p}'$，然后计算每个点的去质心坐标：

$$\boldsymbol{q}_i = \boldsymbol{p}_i - \boldsymbol{p}, \quad \boldsymbol{q}_i' = \boldsymbol{p}_i' - \boldsymbol{p}'.$$

$$\boldsymbol{p} = \frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{p}_i)$$

$$\boldsymbol{p}' = \frac{1}{n}\sum_{i=1}^{n}(\boldsymbol{p}_i')$$

2. 根据以下优化问题计算旋转矩阵：

$$\boldsymbol{R}^* = \arg\min_{\boldsymbol{R}} \frac{1}{2}\sum_{i=1}^{n} \|\boldsymbol{q}_i - \boldsymbol{R}\boldsymbol{q}_i'\|^2. \tag{7.52}$$

3. 根据第二步的 $\boldsymbol{R}$，计算 $\boldsymbol{t}$：

$$\boldsymbol{t}^* = \boldsymbol{p} - \boldsymbol{R}\boldsymbol{p}'. \tag{7.53}$$

其中，第 2 步计算过程如下：

关注 $\boldsymbol{R}$ 的计算。展开关于 $\boldsymbol{R}$ 的误差项，得：

$$\frac{1}{2}\sum_{i=1}^{n}\left\|\boldsymbol{q}_i-\boldsymbol{R}\boldsymbol{q}_i'\right\|^2=\frac{1}{2}\sum_{i=1}^{n}\boldsymbol{q}_i^T\boldsymbol{q}_i+\boldsymbol{q}_i'^T\boldsymbol{R}^T\boldsymbol{R}\boldsymbol{q}_i'-2\boldsymbol{q}_i^T\boldsymbol{R}\boldsymbol{q}_i'. \tag{7.54}$$

注意到第一项和 $\boldsymbol{R}$ 无关，第二项由于 $\boldsymbol{R}^T\boldsymbol{R}=\boldsymbol{I}$，亦与 $\boldsymbol{R}$ 无关。因此，实际上优化目标函数变为：

$$\sum_{i=1}^{n}-\boldsymbol{q}_i^T\boldsymbol{R}\boldsymbol{q}_i'=\sum_{i=1}^{n}-\mathrm{tr}\left(\boldsymbol{R}\boldsymbol{q}_i'\boldsymbol{q}_i^T\right)=-\mathrm{tr}\left(\boldsymbol{R}\sum_{i=1}^{n}\boldsymbol{q}_i'\boldsymbol{q}_i^T\right). \tag{7.55}$$

接下来，我们介绍怎样通过 SVD 解出上述问题中最优的 $\boldsymbol{R}$，但是关于最优性的证明较为复杂，感兴趣的读者请参考 [50, 51]。为了解 $\boldsymbol{R}$，先定义矩阵：

$$\boldsymbol{W}=\sum_{i=1}^{n}\boldsymbol{q}_i\boldsymbol{q}_i'^T. \tag{7.56}$$

$\boldsymbol{W}$ 是一个 $3\times3$ 的矩阵，对 $\boldsymbol{W}$ 进行 SVD 分解，得：

$$\boldsymbol{W}=\boldsymbol{U}\boldsymbol{\Sigma}\boldsymbol{V}^T. \tag{7.57}$$

其中，$\boldsymbol{\Sigma}$ 为奇异值组成的对角矩阵，对角线元素从大到小排列，而 $\boldsymbol{U}$ 和 $\boldsymbol{V}$ 为正交矩阵。当 $\boldsymbol{W}$ 满秩时，$\boldsymbol{R}$ 为：

$$\boldsymbol{R}=\boldsymbol{U}\boldsymbol{V}^T. \tag{7.58}$$

解得 $\boldsymbol{R}$ 后，按式（7.53）求解 $\boldsymbol{t}$ 即可。

## 4.2 非线性优化方法

求解 ICP 的另一种方式是使用非线性优化，以迭代的方式去找最优值。该方法和我们前面讲述的 PnP 非常相似。以李代数表达位姿时，目标函数可以写成：

$$\min_{\boldsymbol{\xi}}=\frac{1}{2}\sum_{i=1}^{n}\left\|\left(\boldsymbol{p}_i-\exp\left(\boldsymbol{\xi}^\wedge\right)\boldsymbol{p}_i'\right)\right\|_2^2. \tag{7.59}$$

单个误差项关于位姿导数已经在前面推导过了，使用李代数扰动模型即可：

$$\frac{\partial\boldsymbol{e}}{\partial\delta\boldsymbol{\xi}}=-\left(\exp\left(\boldsymbol{\xi}^\wedge\right)\boldsymbol{p}_i'\right)^\odot. \tag{7.60}$$

于是，在非线性优化中只需不断迭代，我们就能找到极小值。而且，可以证明 [6]，ICP 问题存在唯一解或无穷多解的情况。在唯一解的情况下，只要我们能找到极小值解，那么**这个极小值就是全局最优值**——因此不会遇到局部极小而非全局最小的情况。这也意味着 ICP 求解可以任意选定初始值。这是已经匹配点时求解 ICP 的一大好处。

需要说明的是，我们这里讲的 ICP，是指已经由图像特征给定了匹配的情况下，进行位姿估计的问题。在匹配已知的情况下，这个最小二乘问题实际上具有解析解 [52, 53, 54]，所以并没有必要进行迭代优化。ICP 的研究者们往往更加关心匹配未知的情况。不过，在 RGB-D SLAM 中，由于一个像素的深度数据可能测量不到，所以我们可以混合着使用 PnP 和 ICP 优化：对于深度已知的特征点，用建模它们的 3D-3D 误差；对于深度未知的特征点，则建模 3D-2D 的重投影误差。于是，可以将所有的误差放在同一个问题中考虑，使得求解更加方便。