一．卡尔曼滤波的引出

$$P(\boldsymbol{x}_k|\boldsymbol{x}_0,\boldsymbol{u}_{1:k},\boldsymbol{z}_{1:k-1})=\int P(\boldsymbol{x}_k|\boldsymbol{x}_{k-1},\boldsymbol{x}_0,\boldsymbol{u}_{1:k},\boldsymbol{z}_{1:k-1})P(\boldsymbol{x}_{k-1}|\boldsymbol{x}_0,\boldsymbol{u}_{1:k},\boldsymbol{z}_{1:k-1})\,\mathrm{d}\boldsymbol{x}_{k-1}$$

根据《优化丨状态估计问题》2.3 节所述，马尔可夫性：k 时刻状态只与 k–1 时刻状态有关。将如下公式简化：

（1）右侧第一部分：对应 k 时刻的运动方程。

$$P(\boldsymbol{x}_k|\boldsymbol{x}_{k-1},\boldsymbol{x}_0,\boldsymbol{u}_{1:k},\boldsymbol{z}_{1:k-1})=P(\boldsymbol{x}_k|\boldsymbol{x}_{k-1},\boldsymbol{u}_k)$$

（2）右侧第二部分：k-1 时刻的状态分布。

$$P(\boldsymbol{x}_{k-1}|\boldsymbol{x}_0,\boldsymbol{u}_{1:k},\boldsymbol{z}_{1:k-1})=P(\boldsymbol{x}_{k-1}|\boldsymbol{x}_0,\boldsymbol{u}_{1:k-1},\boldsymbol{z}_{1:k-1})$$

因此，KF、EKF：把 k-1 时刻的状态分布推导至 k 时刻。（程序运行期间，只要维护一个状态量，对它进行不断地迭代和更新即可）

二．线性系统和 KF

1.1 推导

线性系统：运动、观测方程可由线性方程表示：

$$\begin{cases}\boldsymbol{x}_k=\boldsymbol{A}_k\boldsymbol{x}_{k-1}+\boldsymbol{u}_k+\boldsymbol{\omega}_k, & \boldsymbol{\omega}_k\sim N(\boldsymbol{0},\boldsymbol{R})\\ \boldsymbol{z}_k=\boldsymbol{C}_k\boldsymbol{x}_k+\boldsymbol{v}_k, & \boldsymbol{v}_k\sim N(\boldsymbol{0},\boldsymbol{Q})\end{cases}$$

KF 目标：假设已知 k-1 时刻的后验状态估计：$\hat{\boldsymbol{x}}_{k-1}$和它的协方差$\hat{\boldsymbol{P}}_{k-1}$。根据 k 时刻的输入和观测数据，确定的后验分布$\hat{\boldsymbol{x}}_k$。（记：$\hat{\boldsymbol{x}}_k$后验，$\overline{\boldsymbol{x}}$先验，$\hat{\boldsymbol{P}}_k$协方差）

（1）**预测。**从运动方程出发，根据高斯分布性质：

$$P(\boldsymbol{x}_k|\boldsymbol{x}_0,\boldsymbol{u}_{1:k},\boldsymbol{z}_{1:k-1})=N\left(\boldsymbol{A}_k\hat{\boldsymbol{x}}_{k-1}+\boldsymbol{u}_k,\boldsymbol{A}_k\hat{\boldsymbol{P}}_{k-1}{\boldsymbol{A}_k}^T+\boldsymbol{R}\right)$$

从上一个时刻的状态$\hat{\boldsymbol{x}}_{k-1}$，根据输入信息（有噪声），推断当前时刻的状态分布$\overline{\boldsymbol{x}}_k$。得到预测方程：

$$\overline{\boldsymbol{x}}_k=\boldsymbol{A}_k\hat{\boldsymbol{x}}_{k-1}+\boldsymbol{u}_k,\qquad \overline{\boldsymbol{P}}_k=\boldsymbol{A}_k\hat{\boldsymbol{P}}_{k-1}{\boldsymbol{A}_k}^T+\boldsymbol{R}$$

（2）**更新。**从观测方程出发：

另一方面，由观测方程，我们可以计算在某个状态下，应该产生怎样的观测数据：

$$P\left(\boldsymbol{z}_k|\boldsymbol{x}_k\right)=N\left(\boldsymbol{C}_k\boldsymbol{x}_k,\boldsymbol{Q}\right). \tag{10.13}$$

为了得到后验概率，我们想要计算它们的乘积，也就是由式（10.5）给出的贝叶斯公式。然而，虽然我们知道最后会得到一个关于 $\boldsymbol{x}_k$ 的高斯分布，但计算上是有一丁点儿麻烦的，我们先把结果设为 $\boldsymbol{x}_k\sim N(\hat{\boldsymbol{x}}_k,\hat{\boldsymbol{P}}_k)$，那么：

$$N(\hat{\boldsymbol{x}}_k,\hat{\boldsymbol{P}}_k)=N\left(\boldsymbol{C}_k\boldsymbol{x}_k,\boldsymbol{Q}\right)\cdot N(\bar{\boldsymbol{x}}_k,\bar{\boldsymbol{P}}_k). \tag{10.14}$$

这里我们稍微用点讨巧的方法。既然我们已经知道等式两侧都是高斯分布，那就只需比较指数部分即可，而无须理会高斯分布前面的因子部分。指数部分很像是一个二次型的配方，我们来推导一下。首先把指数部分展开，有[①]：

$$\left(\boldsymbol{x}_k-\hat{\boldsymbol{x}}_k\right)^T\hat{\boldsymbol{P}}_k^{-1}\left(\boldsymbol{x}_k-\hat{\boldsymbol{x}}_k\right)=\left(\boldsymbol{z}_k-\boldsymbol{C}_k\boldsymbol{x}_k\right)^T\boldsymbol{Q}^{-1}\left(\boldsymbol{z}_k-\boldsymbol{C}_k\boldsymbol{x}_k\right)+\left(\boldsymbol{x}_k-\bar{\boldsymbol{x}}_k\right)^T\bar{\boldsymbol{P}}_k^{-1}\left(\boldsymbol{x}_k-\bar{\boldsymbol{x}}_k\right). \tag{10.15}$$

为了求左侧的 $\hat{\boldsymbol{x}}_k$ 和 $\hat{\boldsymbol{P}}_k$，我们把两边展开，并比较 $\boldsymbol{x}_k$ 的二次和一次系数。对于二次系数，有：

$$\hat{\boldsymbol{P}}_k^{-1}=\boldsymbol{C}_k^T\boldsymbol{Q}^{-1}\boldsymbol{C}_k+\bar{\boldsymbol{P}}_k^{-1}. \tag{10.16}$$

该式给出了协方差的计算过程。为了便于后边列写式子，定义一个中间变量：

$$\boldsymbol{K}=\hat{\boldsymbol{P}}_k\boldsymbol{C}_k^T\boldsymbol{Q}^{-1}. \tag{10.17}$$

根据此定义，在式（10.16）左右各乘 $\hat{\boldsymbol{P}}_k$，有：

$$\boldsymbol{I}=\hat{\boldsymbol{P}}_k\boldsymbol{C}_k^T\boldsymbol{Q}^{-1}\boldsymbol{C}_k+\hat{\boldsymbol{P}}_k\bar{\boldsymbol{P}}_k^{-1}=\boldsymbol{K}\boldsymbol{C}_k+\hat{\boldsymbol{P}}_k\bar{\boldsymbol{P}}_k^{-1}. \tag{10.18}$$

于是有[②]：

$$\hat{\boldsymbol{P}}_k=(\boldsymbol{I}-\boldsymbol{K}\boldsymbol{C}_k)\bar{\boldsymbol{P}}_k. \tag{10.19}$$

然后再比较一次项的系数，有：

$$-2\hat{\boldsymbol{x}}_k^T\hat{\boldsymbol{P}}_k^{-1}\boldsymbol{x}_k=-2\boldsymbol{z}_k^T\boldsymbol{Q}^{-1}\boldsymbol{C}_k\boldsymbol{x}_k-2\bar{\boldsymbol{x}}_k^T\bar{\boldsymbol{P}}_k^{-1}\boldsymbol{x}_k. \tag{10.20}$$

整理（取系数并转置）得：

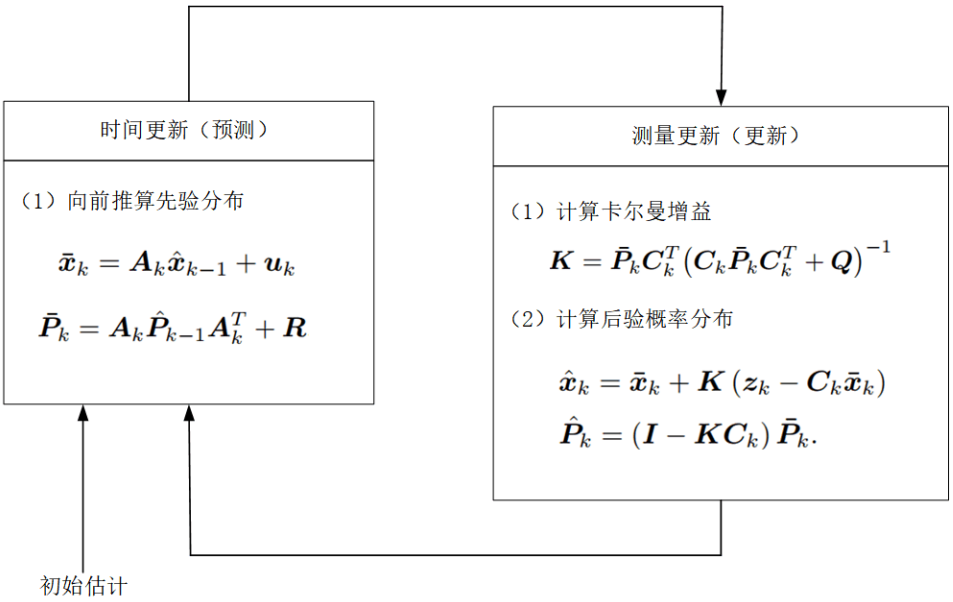
$$\hat{\boldsymbol{P}}_k^{-1}\hat{\boldsymbol{x}}_k=\boldsymbol{C}_k^T\boldsymbol{Q}^{-1}\boldsymbol{z}_k+\bar{\boldsymbol{P}}_k^{-1}\bar{\boldsymbol{x}}_k. \tag{10.21}$$

两侧乘以 $\hat{\boldsymbol{P}}_k$ 并代入式（10.17），得：

$$\hat{\boldsymbol{x}}_k=\hat{\boldsymbol{P}}_k\boldsymbol{C}_k^T\boldsymbol{Q}^{-1}\boldsymbol{z}_k+\hat{\boldsymbol{P}}_k\bar{\boldsymbol{P}}_k^{-1}\bar{\boldsymbol{x}}_k \tag{10.22}$$

$$=\boldsymbol{K}\boldsymbol{z}_k+(\boldsymbol{I}-\boldsymbol{K}\boldsymbol{C}_k)\bar{\boldsymbol{x}}_k=\bar{\boldsymbol{x}}_k+\boldsymbol{K}\left(\boldsymbol{z}_k-\boldsymbol{C}_k\bar{\boldsymbol{x}}_k\right). \tag{10.23}$$

1.2 总结



三. 非线性系统和 EKF

SLAM 中运动、观测方程通常是非线性的，非线性系统：

$$\begin{cases} x_k = f(x_{k-1}, u_k) + \omega_k, & \omega_k \sim N(0, R) \\ z_k = h(x_k) + v_k, & v_k \sim N(0, Q) \end{cases}$$

在 k 时刻，我们把运动方程和观测方程，在 $\hat{\boldsymbol{x}}_{k-1}, \hat{\boldsymbol{P}}_{k-1}$ 处进行**线性化**（相当于一阶泰勒展开），有：

$$\boldsymbol{x}_k \approx f\left(\hat{\boldsymbol{x}}_{k-1}, \boldsymbol{u}_k\right) + \left.\frac{\partial f}{\partial \boldsymbol{x}_{k-1}}\right|_{\hat{\boldsymbol{x}}_{k-1}} \left(\boldsymbol{x}_{k-1} - \hat{\boldsymbol{x}}_{k-1}\right) + \boldsymbol{w}_k. \tag{10.27}$$

记这里的偏导数为：

$$\boldsymbol{F} = \left.\frac{\partial f}{\partial \boldsymbol{x}_{k-1}}\right|_{\hat{\boldsymbol{x}}_{k-1}}. \tag{10.28}$$

同样的，对于观测方程，亦有：

$$\boldsymbol{z}_k \approx h\left(\bar{\boldsymbol{x}}_k\right) + \left.\frac{\partial h}{\partial \boldsymbol{x}_k}\right|_{\bar{\boldsymbol{x}}_k} \left(\boldsymbol{x}_k - \hat{\boldsymbol{x}}_k\right) + \boldsymbol{n}_k. \tag{10.29}$$

记这里的偏导数为：

$$\boldsymbol{H} = \left.\frac{\partial h}{\partial \boldsymbol{x}_k}\right|_{\bar{\boldsymbol{x}}_k}. \tag{10.30}$$

那么，在**预测**步骤中，根据运动方程有：

$$P\left(\boldsymbol{x}_k | \boldsymbol{x}_0, \boldsymbol{u}_{1:k}, \boldsymbol{z}_{0:k-1}\right) = N(f\left(\hat{\boldsymbol{x}}_{k-1}, \boldsymbol{u}_k\right), \boldsymbol{F}\hat{\boldsymbol{P}}_{k-1}\boldsymbol{F}^{\mathrm{T}} + \boldsymbol{R}_k). \tag{10.31}$$

这些推导和卡尔曼滤波是十分相似的。为方便表述，记这里先验和协方差的均值为

$$\bar{\boldsymbol{x}}_k = f\left(\hat{\boldsymbol{x}}_{k-1}, \boldsymbol{u}_k\right), \quad \bar{\boldsymbol{P}}_k = \boldsymbol{F}\hat{\boldsymbol{P}}_k\boldsymbol{F}^T + \boldsymbol{R}_k. \tag{10.32}$$

然后，考虑在观测中，我们有：

$$P\left(\boldsymbol{z}_k | \boldsymbol{x}_k\right) = N(h\left(\bar{\boldsymbol{x}}_k\right) + \boldsymbol{H}\left(\boldsymbol{x}_k - \bar{\boldsymbol{x}}_k\right), \boldsymbol{Q}_k). \tag{10.33}$$

最后，根据最开始的 Bayes 展开式，可以推导出 $\boldsymbol{x}_k$ 的后验概率形式。我们略去中间的推导过程，只介绍其结果。读者可以仿照着卡尔曼滤波器的方式，推导 EKF 的预测与更新方程。简而言之，我们会先定义一个**卡尔曼增益** $\boldsymbol{K}_k$：

$$\boldsymbol{K}_k = \bar{\boldsymbol{P}}_k\boldsymbol{H}^{\mathrm{T}}\left(\boldsymbol{H}\bar{\boldsymbol{P}}_k\boldsymbol{H}^{\mathrm{T}} + \boldsymbol{Q}_k\right)^{-1}. \tag{10.34}$$

在卡尔曼增益的基础上，后验概率的形式为：

$$\hat{\boldsymbol{x}}_k = \bar{\boldsymbol{x}}_k + \boldsymbol{K}_k\left(\boldsymbol{z}_k - h\left(\bar{\boldsymbol{x}}_k\right)\right), \hat{\boldsymbol{P}}_k = \left(\boldsymbol{I} - \boldsymbol{K}_k\boldsymbol{H}\right)\bar{\boldsymbol{P}}_k. \tag{10.35}$$

卡尔曼滤波器给出了在线性化之后，状态变量分布的变化过程。在线性系统和高斯噪声下，卡尔曼滤波器给出了无偏最优估计。而在 SLAM 这种非线性的情况下，它给出了单次线性近似下最大后验估计（MAP）。